

Национальный исследовательский университет
«Высшая школа экономики»

КУРСОВАЯ РАБОТА

на тему:

**«Многомерный анализ корпоративных и
статистических факторов риска:
вероятностное моделирование, факторные структуры
и оптимизация портфеля»**

Авторы:

Моисеев Егор

Юсуфова Полина

СОДЕРЖАНИЕ

Введение	2
1 Обзор литературы	3
1.1 От портфельного выбора к проблеме оценки риска	3
1.2 Факторные модели и роль корпоративных характеристик	4
1.3 PCA/МГК как способ выделить скрытую структуру рынка	4
1.4 Динамика ковариаций и корреляционный риск	5
1.5 Хвостовые меры риска и CVaR-постановка	5
2 ТЕОРЕТИЧЕСКАЯ ЧАСТЬ И ПОСТАНОВКА МОДЕЛИ	7
2.1 Обозначения и подготовка данных	7
2.2 Ковариационная и корреляционная структура доходностей	9
2.3 PCA/SVD и выделение статистических факторов	14
2.4 Матричная регрессия и факторная аппроксимация риска	18
2.5 Включение корпоративных характеристик в модель	20
2.6 Портфельный риск и классическая оптимизация Марковица	21
2.7 VaR, ES и CVaR-оптимизация	26
2.8 Как объединяются три подхода в единой схеме	27
3 ЭМПИРИЧЕСКАЯ ПРОВЕРКА	29
4 РАСЧЕТНАЯ СПЕЦИФИКАЦИЯ МОДЕЛИ И ДАННЫЕ	30
5 ЭМПИРИЧЕСКАЯ ЧАСТЬ: РАСШИРЕННАЯ ВЫБОРКА, КОРПОРАТИВНЫЕ ПРИЗНАКИ И ПОРТФЕЛЬНАЯ ПРОВЕРКА	33
5.1 Описательная статистика и неоднородность доходностей	33
5.2 Корреляционная структура и PCA/МГК	34
5.3 Факторная ковариация и Ledoit-Wolf shrinkage	36
5.4 Корпоративные признаки и PCA-нагрузки	37
5.5 Статическая проверка 2024–2025 гг.	37
5.6 Rolling-window проверка	39
5.7 Ограничения эмпирической части	40
5.8 Итог по эмпирической части	41
5.9 Распределение обязанностей:	41
5.10 Использование ИИ:	41
ЗАКЛЮЧЕНИЕ	42
СПИСОК ЛИТЕРАТУРЫ	43

Введение

Финансовый рынок редко ведет себя как набор независимых активов. Доходности акций зависят не только от собственных характеристик компаний, но и от общего рыночного движения, отраслевых и макроэкономических шоков, изменения корреляций и неблагоприятных событий, которые проявляются в хвостах распределения доходностей. Поэтому в задаче оптимизации риска портфеля недостаточно отдельно рассмотреть среднюю доходность каждой бумаги, надо одновременно учесть: 1. ковариации между бумагами; 2. факторные источники риска - какие-то непредсказуемые события масштаба страны или отрасли, которые бьют по всем компаниям на рынке; 3. корпоративные характеристики эмитентов - финансовые и операционные показатели компаний; 4. реализованные потери портфеля - реальный зафиксированный убыток после продаж упавших акций.

Теоретически эта логика опирается на несколько связанных направлений литературы. Работа Марковица (за которую он получил нобелевскую премию, кстати) показывает, что риск портфеля определяется не только волатильностью отдельных бумаг, но и ковариациями между ними [1]. Факторные модели переходят от описания отдельных активов к общим источникам доходности и риска - явным характеристикам компаний и скрытым глобальным рыночным факторам [2–4]. Метод главных компонент позволяет выделить статистические факторы из эмпирической матрицы доходностей, а устойчивые оценки ковариаций, включая Ledoit–Wolf shrinkage, уменьшают чувствительность оптимизации к шуму в данных [5, 8]. А квантильные и когерентные меры риска (Expected Shortfall и CVaR) дополняют подход Марковица анализом худших хвостовых сценариев [6, 7].

Предметом исследования является связь между корпоративными характеристиками российских публичных компаний, статистической факторной структурой доходностей и реализованными мерами риска портфельных стратегий (фактического результата портфеля).

Целью работы является построение и оценка портфельного подхода для 25 акций Московской биржи на дневных данных за период 03.01.2019–30.12.2025, в котором рыночный риск описывается через ковариационную и корреляционную структуру доходностей, факторный риск выделяется методом главных компонент, корпоративные характеристики используются по правилу as-of (не подглядывая в данные будущего периода), а результаты стратегий сравниваются с равновзвешенным портфелем на статическом вневыборочном периоде 2024–2025 гг. и в rolling-window проверке по годовой доходности, волатильности, коэффициенту Sharpe, VaR 95%, ES 95%, максимальной просадке и концентрации весов.

Для достижения этой цели в работе решаются следующие задачи:

1. сформировать рабочую выборку акций Московской биржи и построить синхронизированную матрицу дневных логарифмических доходностей;
2. рассчитать описательные характеристики доходностей, ковариационную и корреляционную матрицу;

- ляционную матрицы, показатели хвостового риска и просадок;
3. провести PCA/МГК на обучающем окне и определить число компонент, достаточное для описания основной части вариации доходностей;
 4. сравнить выборочную, факторную и Ledoit–Wolf оценки ковариационной матрицы как основы портфельного риск-ядра;
 5. построить корпоративную матрицу признаков с учетом дат доступности отчетности и использовать ее для корпоративного сигнала и интерпретации факторных нагрузок;
 6. сформировать и сравнить портфельные стратегии: равные веса, портфель минимальной дисперсии, CVaR-ориентированный портфель, корпоративно-смещенный портфель и итоговый портфель, выбранный через внутреннюю проверочную процедуру;
 7. оценить устойчивость результатов на статическом тестовом периоде 2024–2025 гг. и в rolling-window режиме, не используя будущую информацию при формировании весов

Рабочая гипотеза состоит в том, что сочетание статистического риск-ядра, PCA-факторов, корпоративных признаков и хвостовых метрик риска дает более содержательную и проверяемую портфельную схему, чем использование каждого блока отдельно. При этом мы не предполагаем заранее, что сложная стратегия обязательно превзойдет равновзвешенный портфель по всем метрикам. Напротив, равновзвешенная стратегия используется как строгая базовая точка сравнения: если модель выигрывает только внутри обучающей выборки, но теряет преимущество на будущих данных, такой результат должен интерпретироваться осторожно.

1 Обзор литературы

Обзор литературы в данной работе выстроен не как отдельный перечень статей, а как переход от базовой портфельной постановки к тем элементам, которые используются в эмпирической части: ковариационной матрице, факторной структуре, методу главных компонент, корпоративным признакам, хвостовым мерам риска и сравнению с простым базовым портфелем.

1.1 От портфельного выбора к проблеме оценки риска

Отправной точкой является работа Марковица [1]. Ее значение для нашей темы состоит в переходе от оценки отдельных активов к совместному анализу их доходности и риска. Здесь общий риск портфеля определяется не столько волатильностью конкретных бумаг, сколько ковариациями между ними. И добавление новой бумаги полезно не само по себе, а только если оно меняет общую структуру риска. Именно

поэтому в нашей работе сначала строится матрица логарифмических доходностей, а затем анализируются ковариации, корреляции и портфельные веса.

Работа Ledoit и Wolf [5] напрямую отвечает на эту проблему: авторы предлагают улучшать оценку ковариационной матрицы через shrinkage, то есть через сжатие выборочной матрицы к более стабильной целевой структуре. Для нашей работы это важно методологически: мы не отказываемся от ковариационного подхода, но проверяем, кардинально ли набор самых значимых активов в портфеле меняется при замене выборочной матрицы на Ledoit–Wolf оценку. В эмпирической части это реализовано через стратегию MinVar_LW и сравнение с MinVar_sample.

1.2 Факторные модели и роль корпоративных характеристик

Если Марковиц показывает, как использовать ковариации для выбора портфеля, то факторные модели объясняют, почему доходности разных бумаг движутся совместно. Работы Fama и French [2, 3] показывают, что различия в доходностях акций нельзя сводить только к рыночному фактору. Размер компании, относительная рыночная оценка и другие характеристики могут быть связаны с премиями за риск. Для нашей работы это обосновывает включение корпоративных показателей: капитализации, P/E, P/B, ROE, долговой нагрузки, дивидендной доходности и free float.

Важный вывод из этих работ состоит в том, что корпоративные признаки не должны восприниматься как случайное дополнение к ценовым рядам. Они помогают перейти от чисто статистического описания доходностей к экономической интерпретации различий между компаниями. Поэтому в эмпирической части корпоративная матрица Z используется в двух ролях: во-первых, как источник корпоративного сигнала ожидаемой доходности; во-вторых, как инструмент объяснения нагрузок на главные компоненты.

Работа Lyle и Yohn [9] ближе всего к этой части нашего проекта, потому что связывает фундаментальный анализ с портфельной оптимизацией. Для нас важна сама логика: корпоративные данные не заменяют ковариационную матрицу, но могут сделать выбор портфеля менее зависимым от шумных исторических средних доходностей. В нашей модели это отражено в корпоративно-смещенной стратегии CorpTilt_MV, которая строится поверх риск-ядра, а не вместо него.

1.3 PCA/МГК как способ выделить скрытую структуру рынка

Следующий переход – от заранее заданных факторов к факторам, которые выделяются из самих доходностей. Connor и Kojan [4] показывают, что метод главных компонент может использоваться для выделения статистических факторов в больших панелях доходностей. Это важно для портфельной задачи: если общие движения рынка можно описать несколькими компонентами, то ковариационную структуру можно анализировать не только через все попарные связи, но и через ограниченное число факторов.

Chen, Huang и Pan [8] развивают эту идею уже в контексте высокоразмерной mean-variance-оптимизации. Их результат поддерживает использование факторной структуры как способа уменьшить шум в ковариационной матрице. В нашей работе это соответствует сравнению трех вариантов матрицы риска: выборочной ковариации, факторной PCA-аппроксимации и Ledoit–Wolf оценки.

Для российского рынка важны работы, показывающие применимость многомерных методов именно к отечественным финансовым данным. Галустян [10] рассматривает метод главных компонент как способ отбора факторов для прогнозирования фондового рынка России. Крицкий и Ульянова [11] используют многомерную постановку риска портфеля и показывают, почему анализ активов по отдельности может недооценивать общий риск. Эти работы позволяют связать западную факторную литературу с нашей эмпирической задачей по акциям Московской биржи.

1.4 Динамика ковариаций и корреляционный риск

Отдельная проблема состоит в том, что ковариации и корреляции не являются постоянными. Кретинин [12] рассматривает модели условной гетероскедастичности для ковариаций доходностей финансовых активов. Мы не строим полноценную GARCH-модель, но учитываем тот же методологический вывод: риск меняется во времени, поэтому одной статической оценки может быть недостаточно.

Работа Едроновой и Россохина [13] важна для интерпретации российского рынка: даже если портфель формально диверсифицирован по числу бумаг, скрытые корреляционные связи могут сохранять концентрацию риска. Поэтому в нашей эмпирической части анализ корреляционной матрицы не является техническим приложением. Он нужен для понимания того, насколько расширение выборки действительно снижает совместный риск и какие сектора движутся синхронно.

Связь с нашей моделью здесь прямая: PCA показывает обобщенные направления совместного движения, Ledoit–Wolf стабилизирует матрицу риска, а rolling-window проверка показывает, меняется ли качество стратегий при последовательном обновлении данных. Тем самым мы не ограничиваемся одной оценкой ковариаций на всем периоде, а проверяем, как портфельная схема ведет себя в разных окнах 2024–2025 гг.

1.5 Хвостовые меры риска и CVaR-постановка

Классическая дисперсия удобна математически, но она не различает обычную волатильность и редкие крупные убытки. Acerbi и Tasche [6] обосновывают Expected Shortfall как более информативную меру хвостового риска по сравнению с одним только VaR. Для нашей работы это важно потому, что российские акции могут иметь тяжелые хвосты: отдельные резкие падения не всегда хорошо отражаются средним стандартным отклонением.

Rockafellar и Uryasev [7] показывают, как оптимизировать Conditional Value-at-Risk через удобную вычислительную постановку. Это дает основание включить в сравнение MinCVaR: стратегия не обязана максимизировать среднюю доходность, но

должна проверять, можно ли уменьшить средний убыток в худших сценариях. Российская работа Кудрявцева [14] также важна как пример перехода от дисперсионных критериев к квантильным мерам риска в задаче портфельного выбора.

Итоговая логика обзора следующая. Теория Марковица задает портфельную постановку; факторные модели и корпоративные характеристики объясняют различия между активами; PCA и факторный анализ позволяют уменьшить размерность и выделить общие движения; shrinkage помогает стабилизировать ковариационную матрицу; VaR, ES и CVaR добавляют оценку худших сценариев. Именно эта последовательность и используется в нашей эмпирической части: от матрицы доходностей и корпоративной панели – к факторной структуре, портфельным весам и проверочным метрикам.

Таблица 1. Логика группировки литературы и ее роль в работе

Блок	Ключевые источники	Идея	Роль в нашей модели
Портфельный выбор	[1]	Риск портфеля зависит от дисперсий и ковариаций активов.	Базовая постановка оптимизации и сравнение с равными весами.
Факторные и корпоративные признаки	[2, 3, 9]	Доходности связаны с рыночными и фирменными характеристиками.	Корпоративная матрица Z и экономическая интерпретация различий между бумагами.
PCA/МГК и факторная ковариация	[4, 8, 10, 11]	Высокоразмерный риск можно описывать через небольшое число общих факторов.	PCA-блок, факторные нагрузки и факторная аппроксимация ковариаций.
Устойчивость ковариаций и корреляций	[5, 12, 13]	Выборочные ковариации шумны, а корреляции могут меняться во времени.	Ledoit–Wolf риск-ядро и rolling-window проверка.
Хвостовой риск	[6, 7, 14]	VaR/ES/CVaR описывают неблагоприятные сценарии, которые не видны через одну дисперсию.	Расчет VaR 95%, ES 95% и сравнение с CVaR-ориентированной стратегией.

2 ТЕОРЕТИЧЕСКАЯ ЧАСТЬ И ПОСТАНОВКА МОДЕЛИ

Ниже мы выписываем обозначения и базовые формулы.

Таблица 2. Основные обозначения, используемые в теоретической части

Обозначение	Смысл
N	число анализируемых акций в выборке
T	число временных наблюдений
P_{it}	цена i -й акции в момент времени t
r_{it}	логарифмическая доходность i -й акции в момент t
r_t	вектор доходностей всех N активов в момент t
R	матрица доходностей размерности $T \times N$
μ	вектор ожидаемых доходностей активов
X	центрированная матрица доходностей
Σ	ковариационная матрица доходностей
C	корреляционная матрица
F	матрица выделенных факторов
B	матрица факторных нагрузок
E	матрица остатков факторной модели
Z	матрица корпоративных характеристик компаний
w	вектор весов портфеля
μ_p	ожидаемая доходность портфеля
σ_p^2	дисперсия доходности портфеля
VaR_β	β -квантиль распределения потерь (β - уровень доверия)
ES_β	Expected Shortfall на уровне доверия β

2.1 Обозначения и подготовка данных

Теоретическую часть начнем с введения обозначений. Пусть в выборке рассматриваются N акций и T моментов наблюдения. Через P_{it} обозначим цену i -й акции в момент t . Тогда базовой величиной в работе будет логарифмическая доходность.

$$r_{it} = \ln \left(\frac{P_{it}}{P_{i,t-1}} \right), \quad i = 1, \dots, N, \quad t = 2, \dots, T.$$

Здесь r_{it} — логарифмическая доходность i -й акции, P_{it} — цена этой акции в момент t . Использование логарифмических доходностей удобно тем, что при небольших изменениях цен они близки к обычным процентным доходностям (утверждение 1), а при последовательном накоплении периодов аддитивны по времени (утверждение 2)

Докажем утверждение 1:

$R_{it} = \frac{P_{it}-P_{i,t-1}}{P_{i,t-1}} = \frac{P_{it}}{P_{i,t-1}} - 1$ — процентная доходность i -го актива в момент t . Перенесем 1 влево: $\frac{P_{it}}{P_{i,t-1}} = 1 + R_{it}$. Подставим это выражение в формулу логарифмической доходности и используем разложение в ряд Тейлора для $\ln(1+x)$ при $x \rightarrow 0$, получаем:

$$r_{it} = \ln(1 + R_{it}) = R_{it} - \frac{R_{it}^2}{2} + \frac{R_{it}^3}{3} - \dots$$

$$r_{it} \approx R_{it}, \quad \text{при } R_{it} \rightarrow 0$$

При маленьком R_{it} это работает, мы это разложение используем только для дневных доходностей (потому что если доходность не стремится к нулю, то формула Тейлора не работает). Посмотреть годовую доходность поможет утверждение 2.

Докажем утверждение 2:

Когда мы просто доходности считаем, проценты просто просуммировать нельзя. Но для логарифмов доходностей это сделать можно, и получится вот что:

$$\sum_{t=1}^T r_{it} = \sum_{t=1}^T \ln\left(\frac{P_{it}}{P_{i,t-1}}\right) = \ln\left(\prod_{t=1}^T \frac{P_{it}}{P_{i,t-1}}\right) = \ln\left(\frac{P_{i1}}{P_{i0}} \cdot \frac{P_{i2}}{P_{i1}} \cdots \frac{P_{iT}}{P_{i,T-1}}\right) = \ln\left(\frac{P_{iT}}{P_{i0}}\right) = r_{i,0/T}$$

Внутренние члены сократятся, и вычислительно становится легче.

Пойдем дальше

$$r_t = (r_{1t}, r_{2t}, \dots, r_{Nt})^\top.$$

Вектор r_t собирает доходности всех активов в момент времени t . Если расположить такие векторы по строкам, получим матрицу доходностей R размерности $T \times N$.

$$R = [r_t^\top]_{t=1}^T.$$

Матрица R содержит полную панель доходностей. Далее нам понадобится средняя доходность каждого актива за весь рассматриваемый период и центрированная матрица доходностей.

$$\bar{r} = \frac{1}{T} \sum_{t=1}^T r_t, \quad X = R - 1_T \bar{r}^\top.$$

Здесь $\bar{r}$ — вектор выборочных средних доходностей по активам, 1_T — столбец из T единиц, а X — матрица центрированных доходностей. Иными словами, из каждой колонки матрицы R вычитается ее среднее значение. Вот так это выглядит, если расписать:

$$\begin{aligned}
X &= \begin{pmatrix} r_{11} & r_{12} & \dots & r_{1N} \\ r_{21} & r_{22} & \dots & r_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ r_{T1} & r_{T2} & \dots & r_{TN} \end{pmatrix} - \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \times \begin{pmatrix} \bar{r}_1 & \bar{r}_2 & \dots & \bar{r}_N \end{pmatrix} = \\
&= \begin{pmatrix} r_{11} & r_{12} & \dots & r_{1N} \\ r_{21} & r_{22} & \dots & r_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ r_{T1} & r_{T2} & \dots & r_{TN} \end{pmatrix} - \begin{pmatrix} \bar{r}_1 & \bar{r}_2 & \dots & \bar{r}_N \\ \bar{r}_1 & \bar{r}_2 & \dots & \bar{r}_N \\ \vdots & \vdots & \ddots & \vdots \\ \bar{r}_1 & \bar{r}_2 & \dots & \bar{r}_N \end{pmatrix} = \begin{pmatrix} r_{11} - \bar{r}_1 & r_{12} - \bar{r}_2 & \dots & r_{1N} - \bar{r}_N \\ r_{21} - \bar{r}_1 & r_{22} - \bar{r}_2 & \dots & r_{2N} - \bar{r}_N \\ \vdots & \vdots & \ddots & \vdots \\ r_{T1} - \bar{r}_1 & r_{T2} - \bar{r}_2 & \dots & r_{TN} - \bar{r}_N \end{pmatrix}
\end{aligned}$$

Именно X будет использована для ковариационного анализа, PCA и SVD. И введу обозначение $x_{it} = r_{it} - \bar{r}_i$

2.2 Ковариационная и корреляционная структура доходностей

Введем понятия ковариации и корреляции.

Ковариация показывает направление связи между двумя активами. Если ковариация положительная, акции имеют тенденцию двигаться в одну сторону (если одна растет, вторая тоже растет и наоборот, то есть меняются сонаправленно). Если ковариация отрицательная, акции двигаются в противоположнонаправленно. Если ковариация около 0, движение акций вообще никак не связаны.

$$s_{ij} = \text{Cov}(X_i, X_j) = \frac{1}{T-1} \sum_{t=1}^T (r_{it} - \bar{r}_i)(r_{jt} - \bar{r}_j) = \frac{1}{T-1} \sum_{t=1}^T x_{ti}x_{tj} \quad (1)$$

Центральным элементом исследования является ковариационная матрица S , которая показывает, как акции двигаются друг относительно друга. Чтобы составить её, мы используем стандартный выборочный метод: для каждой пары акций рассчитывается сумма произведений их ежедневных отклонений от средних значений.. Чтобы полученная оценка рисков была точной и несмещенной, используем поправку Бесселя (иначе на математическом ожидании оценки рисков (дисперсии) появится множитель $\frac{T-1}{T}$, то есть выборочная дисперсия будет заниженной).

$$S = \frac{1}{T-1} X^\top X \quad (2)$$

Матрица S имеет размер $N \times N$. Распишу ее поэлементно:

$$S = \frac{1}{T-1} \begin{pmatrix} x_{11} & x_{21} & \dots & x_{T1} \\ x_{12} & x_{22} & \dots & x_{T2} \\ \vdots & \vdots & \ddots & \vdots \\ x_{1N} & x_{2N} & \dots & x_{TN} \end{pmatrix} \times \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1N} \\ x_{21} & x_{22} & \dots & x_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ x_{T1} & x_{T2} & \dots & x_{TN} \end{pmatrix} \quad (3)$$

И в результате перемножения матриц получим:

$$S = \begin{pmatrix} \frac{1}{T-1} \sum_{t=1}^T x_{t1}^2 & \frac{1}{T-1} \sum_{t=1}^T x_{t1}x_{t2} & \dots & \frac{1}{T-1} \sum_{t=1}^T x_{t1}x_{tN} \\ \frac{1}{T-1} \sum_{t=1}^T x_{t2}x_{t1} & \frac{1}{T-1} \sum_{t=1}^T x_{t2}^2 & \dots & \frac{1}{T-1} \sum_{t=1}^T x_{t2}x_{tN} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{T-1} \sum_{t=1}^T x_{tN}x_{t1} & \frac{1}{T-1} \sum_{t=1}^T x_{tN}x_{t2} & \dots & \frac{1}{T-1} \sum_{t=1}^T x_{tN}^2 \end{pmatrix} = \begin{pmatrix} s_1^2 & s_{12} & \dots & s_{1N} \\ s_{21} & s_{22} & \dots & s_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ s_{N1} & s_{N2} & \dots & s_N^2 \end{pmatrix} \quad (4)$$

Здесь s_i^2 - это выборочные дисперсии (риск каждой отдельной акции), а элементы s_{ij} вне диагонали — выборочные ковариации между парами активов.

Теперь введем корреляцию. Корреляция — это нормированная ковариация, которая измеряет силу и направление линейной связи между двумя активами. Выражается как отношение выборочной ковариации к произведению выборочных стандартных отклонений активов:

$$\rho_{ij} = \frac{s_{ij}}{s_i \cdot s_j} \quad (5)$$

Подставляем в формулу ковариации и СКО:

$$s_{ij} = \frac{1}{T-1} \sum_{t=1}^T x_{it}x_{jt} \quad (6)$$

$$s_i = \sqrt{\frac{1}{T-1} \sum_{t=1}^T x_{it}^2}, \quad s_j = \sqrt{\frac{1}{T-1} \sum_{t=1}^T x_{jt}^2} \quad (7)$$

$$\begin{aligned} \rho_{ij} &= \frac{\frac{1}{T-1} \sum_{t=1}^T x_{it}x_{jt}}{\sqrt{\frac{1}{T-1} \sum_{t=1}^T x_{it}^2} \cdot \sqrt{\frac{1}{T-1} \sum_{t=1}^T x_{jt}^2}} \\ &= \frac{\frac{1}{T-1} \sum_{t=1}^T x_{it}x_{jt}}{\sqrt{\left(\frac{1}{T-1}\right)^2 \cdot \sum_{t=1}^T x_{it}^2 \cdot \sum_{t=1}^T x_{jt}^2}} \\ &= \frac{\frac{1}{T-1} \sum_{t=1}^T x_{it}x_{jt}}{\frac{1}{T-1} \sqrt{\sum_{t=1}^T x_{it}^2 \cdot \sum_{t=1}^T x_{jt}^2}} \\ &= \frac{\sum_{t=1}^T x_{it}x_{jt}}{\sqrt{\sum_{t=1}^T x_{it}^2 \cdot \sum_{t=1}^T x_{jt}^2}} \end{aligned} \quad (8)$$

Повторимся, что если $s_{ij} > 0$, доходности активов i и j в среднем имеют тенденцию двигаться в одну сторону; если $s_{ij} < 0$, их движения чаще разнонаправлены.

$$D = \text{diag}(s_{11}, s_{22}, \dots, s_{NN}), \quad C = D^{-1/2} S D^{-1/2}.$$

Матрица C — это корреляционная матрица. Она удобна тем, что переводит все масштабы к безразмерной форме и позволяет сравнивать силу связи между активами независимо от уровня их собственной волатильности, в то время как ковариационная матрица показывает только направление связи. Распишу C :

$$D = \text{diag}(s_{11}, s_{22}, \dots, s_{NN}) = \begin{pmatrix} s_1^2 & 0 & \dots & 0 \\ 0 & s_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & s_N^2 \end{pmatrix} \quad (9)$$

Матрица $D^{-1/2}$ обратна к корню из D , выглядит так:

$$D^{-1/2} = \begin{pmatrix} \frac{1}{s_1} & 0 & \dots & 0 \\ 0 & \frac{1}{s_2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \frac{1}{s_N} \end{pmatrix} \quad (10)$$

Подставим в C :

$$C = \begin{pmatrix} \frac{1}{s_1} & 0 & \dots & 0 \\ 0 & \frac{1}{s_2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \frac{1}{s_N} \end{pmatrix} \begin{pmatrix} s_{11}^2 & s_{12} & \dots & s_{1N} \\ s_{21} & s_{22}^2 & \dots & s_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ s_{N1} & s_{N2} & \dots & s_{NN}^2 \end{pmatrix} \begin{pmatrix} \frac{1}{s_1} & 0 & \dots & 0 \\ 0 & \frac{1}{s_2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \frac{1}{s_N} \end{pmatrix} \quad (11)$$

Считаем левое произведение сначала:

$$\begin{aligned} D^{-1/2} S &= \begin{pmatrix} \frac{1}{s_1} & 0 & \dots & 0 \\ 0 & \frac{1}{s_2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \frac{1}{s_N} \end{pmatrix} \begin{pmatrix} s_{11}^2 & s_{12} & \dots & s_{1N} \\ s_{21} & s_{22}^2 & \dots & s_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ s_{N1} & s_{N2} & \dots & s_{NN}^2 \end{pmatrix} \\ &= \begin{pmatrix} \frac{s_{11}^2}{s_1} & \frac{s_{12}}{s_1} & \dots & \frac{s_{1N}}{s_1} \\ \frac{s_{21}}{s_2} & \frac{s_{22}^2}{s_2} & \dots & \frac{s_{2N}}{s_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{s_{N1}}{s_N} & \frac{s_{N2}}{s_N} & \dots & \frac{s_{NN}^2}{s_N} \end{pmatrix} \end{aligned} \quad (12)$$

Умножаем справа на диагональную матрицу $D^{-1/2}$:

$$\begin{aligned}
C = (D^{-1/2}S)D^{-1/2} &= \begin{pmatrix} \frac{s_1^2}{s_1} & \frac{s_{12}}{s_1} & \dots & \frac{s_{1N}}{s_1} \\ \frac{s_{21}}{s_2} & \frac{s_2^2}{s_2} & \dots & \frac{s_{2N}}{s_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{s_{N1}}{s_N} & \frac{s_{N2}}{s_N} & \dots & \frac{s_N^2}{s_N} \end{pmatrix} \begin{pmatrix} \frac{1}{s_1} & 0 & \dots & 0 \\ 0 & \frac{1}{s_2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \frac{1}{s_N} \end{pmatrix} \\
&= \begin{pmatrix} \frac{s_1^2}{s_1 \cdot s_1} & \frac{s_{12}}{s_1 \cdot s_2} & \dots & \frac{s_{1N}}{s_1 \cdot s_N} \\ \frac{s_{21}}{s_2 \cdot s_1} & \frac{s_2^2}{s_2 \cdot s_2} & \dots & \frac{s_{2N}}{s_2 \cdot s_N} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{s_{N1}}{s_N \cdot s_1} & \frac{s_{N2}}{s_N \cdot s_2} & \dots & \frac{s_N^2}{s_N \cdot s_N} \end{pmatrix}
\end{aligned} \tag{13}$$

Все матрицы $N \times N$, значит C такая же. Каждый элемент C представляет собой коэффициент корреляции Пирсона ρ_{ij} :

$$C = \begin{pmatrix} \frac{s_1^2}{s_1 \cdot s_1} & \frac{s_{12}}{s_1 \cdot s_2} & \dots & \frac{s_{1N}}{s_1 \cdot s_N} \\ \frac{s_{21}}{s_2 \cdot s_1} & \frac{s_2^2}{s_2 \cdot s_2} & \dots & \frac{s_{2N}}{s_2 \cdot s_N} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{s_{N1}}{s_N \cdot s_1} & \frac{s_{N2}}{s_N \cdot s_2} & \dots & \frac{s_N^2}{s_N \cdot s_N} \end{pmatrix} = \begin{pmatrix} 1 & \rho_{12} & \dots & \rho_{1N} \\ \rho_{21} & 1 & \dots & \rho_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{N1} & \rho_{N2} & \dots & 1 \end{pmatrix} \tag{14}$$

Вот почему именно такое произведение дает нам корреляционную матрицу.

Вернемся к ковариационной матрице: для нас принципиально важны два ее свойства: Во-первых, она симметрична: $S = S^\top$. Во-вторых, она неотрицательно определена, поскольку для любого вектора весов акций a выполняется $a^\top S a \geq 0$. Это свойство непосредственно связано с тем, что дисперсия любого линейного портфеля не может быть отрицательной. Докажем неотрицательную определенность матрицы S : Подставим $S = \frac{1}{T-1} X^\top X$:

$$a^\top S a = a^\top \left(\frac{1}{T-1} X^\top X \right) a = \frac{1}{T-1} (a^\top X^\top) (X a) \tag{15}$$

Используем свойство матриц $a^\top X^\top = (X a)^\top$, сгруппируем слагаемые:

$$a^\top S a = \frac{1}{T-1} (X a)^\top (X a) \tag{16}$$

X имеет размерность $T \times N$, а a имеет размерность $N \times 1$. Их произведение $X a$ будет $T \times 1$. Тогда $(X a)^\top (X a)$ это число - сумма квадратов элементов вектора $X a$. А сумма квадратов всегда неотрицательна. Докажем, что эта сумма квадратов - это дисперсия

всего портфеля. Рассмотрим элемент из вектора Xa размерности $T \times 1$

$$Xa = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1N} \\ x_{21} & x_{22} & \dots & x_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ x_{t1} & x_{t2} & \dots & x_{tN} \\ \vdots & \vdots & \ddots & \vdots \\ x_{T1} & x_{T2} & \dots & x_{TN} \end{pmatrix} \times \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_N \end{pmatrix} = \begin{pmatrix} x_{11}a_1 + x_{12}a_2 + \dots + x_{1N}a_N \\ x_{21}a_1 + x_{22}a_2 + \dots + x_{2N}a_N \\ \vdots \\ x_{t1}a_1 + x_{t2}a_2 + \dots + x_{tN}a_N \\ \vdots \\ x_{T1}a_1 + x_{T2}a_2 + \dots + x_{TN}a_N \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^N x_{1i}a_i \\ \sum_{i=1}^N x_{2i}a_i \\ \vdots \\ \sum_{i=1}^N x_{ti}a_i \\ \vdots \\ \sum_{i=1}^N x_{Ti}a_i \end{pmatrix} \quad (17)$$

Посмотрим на элементы результата:

$$\sum_{i=1}^N x_{it}a_i = \sum_{i=1}^N a_i(r_{it} - \bar{r}_i) = \sum_{i=1}^N a_i r_{it} - \sum_{i=1}^N a_i \bar{r}_i \quad (18)$$

Интерпретирую каждое слагаемое: $\sum_{i=1}^N a_i r_{it} = r_{p,t}$ — это логарифмическая доходность всего портфеля в день t $\sum_{i=1}^N a_i \bar{r}_i = \bar{r}_p$ — это средняя историческая доходность портфеля за все T дней

То есть каждый элемент вектора Xa — это отклонение доходности портфеля от своего среднего в день t

$$a^\top Sa = \frac{1}{T-1} \sum_{t=1}^T (r_{p,t} - \bar{r}_p)^2 = \hat{\sigma}_p^2 \quad (19)$$

Эта запись полезна не только теоретически. Она показывает, почему квадратичная форма $w^\top \Sigma w$ (обозначения Марковица, у нас $a^\top Sa$) естественным образом возникает в задаче Марковица: риск портфеля — это дисперсия линейной комбинации активов.

$$\text{rank}(S) = \text{rank}(X^\top X) = \text{rank}(X) \leq \min(N, T-1).$$

Эта формула особенно важна для нашей темы. Суть в том, что ранг матрицы X не может быть больше N и не может быть больше T , тк имеет размерность $T \times N$. $T-1$ берем, тк из-за того что в матрице X когда мы вычитали среднее, мы потеряли одну степень свободы, строки ЛЗ и одну надо исключить (тк если мы все элементы матрицы X сложим, мы получим ноль). Случай 1: $T-1 \geq N$ Наблюдений (дней) очень много, активов мало:

$$\min(N, T-1) = N \quad (20)$$

$$\text{rank}(S) \leq N \quad (21)$$

Матрица S и так имеет размерность $N \times N$, а у акций нет идеальной зависимости, они уникальны, поэтому ранг не может быть меньше N :

$$\text{rank}(S) = N \quad (22)$$

То есть выборочная ковариационная матрица S невырожденная.

Случай 2: $T - 1 < N$ Акции много, наблюдений мало. В этом случае функция минимума выбирает $T - 1$:

$$\min(N, T - 1) = T - 1 \quad (23)$$

$$\text{rank}(S) \leq T - 1 < N \quad (24)$$

То есть $\text{rank}(S) < N$. Матрица S становится вырожденной и в ней есть ЛЗ строки. В этом случае ее обращение нестабильно, а значит, и классическая mean-variance-оптимизация Марковица становится чувствительной к шуму. Именно отсюда возникает потребность в факторной аппроксимации и shrinkage-подходах [5, 8].

2.3 PCA/SVD и выделение статистических факторов

Когда размерность задачи велика, естественным шагом становится переход от полного описания N доходностей к меньшему числу общих компонент. В нашей работе для этого используются метод главных компонент и сингулярное разложение. Их смысл одинаков: найти несколько линейных комбинаций исходных доходностей, которые объясняют наибольшую долю общей изменчивости.

$$S = V\Lambda V^T, \quad \Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_N), \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_N \geq 0.$$

Это формула спектрального разложения выборочной матрицы, Здесь V — матрица собственных векторов ковариационной матрицы, а λ_k — соответствующие собственные значения. Чем больше λ_k , тем большую долю изменчивости объясняет k -я главная компонента. Покажем, почему матрица S вообще может так выражаться. Пусть $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_N$ — собственные векторы S , соответствующие её собственным значениям $\lambda_1, \lambda_2, \dots, \lambda_N$. По определению для любой пары собственного значения и собственного вектора выполняется равенство (мы так ищем собственные векторы — $(S - \lambda I)\mathbf{v} = 0$):

$$S\mathbf{v}_k = \lambda_k \mathbf{v}_k \quad (25)$$

Матрица V состоит из собственных векторов как из столбцов: $V = \begin{pmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_N \end{pmatrix}$.

$$V = \begin{pmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_N \end{pmatrix} = \begin{pmatrix} v_{11} & v_{12} & \dots & v_{1N} \\ v_{21} & v_{22} & \dots & v_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ v_{N1} & v_{N2} & \dots & v_{NN} \end{pmatrix} \quad (26)$$

Рассмотрим произведение SV . Его можно расписать так, тк вектор $\mathbf{v}_i$ вообще размерностью $N \times 1$, то если бы мы обычно умножали, мы бы каждую строку S домножали

поочередно на каждый вектор $\mathbf{v}_i$ и получали бы вектор $S\mathbf{v}_i$:

$$SV = S \cdot \begin{pmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_N \end{pmatrix} = \begin{pmatrix} S\mathbf{v}_1 & S\mathbf{v}_2 & \dots & S\mathbf{v}_N \end{pmatrix} \quad (27)$$

Дальше просто пропишем векторы и заменим произведение $S\mathbf{v}_i$ на λv_i , засунем лямбду в вектор и снова сделаем обычную матрицу:

$$SV = \begin{pmatrix} S \begin{pmatrix} v_{11} \\ v_{21} \\ \vdots \\ v_{N1} \end{pmatrix} & S \begin{pmatrix} v_{12} \\ v_{22} \\ \vdots \\ v_{N2} \end{pmatrix} & \dots & S \begin{pmatrix} v_{1N} \\ v_{2N} \\ \vdots \\ v_{NN} \end{pmatrix} \end{pmatrix} = \begin{pmatrix} \lambda_1 \begin{pmatrix} v_{11} \\ v_{21} \\ \vdots \\ v_{N1} \end{pmatrix} & \lambda_2 \begin{pmatrix} v_{12} \\ v_{22} \\ \vdots \\ v_{N2} \end{pmatrix} & \dots & \lambda_N \begin{pmatrix} v_{1N} \\ v_{2N} \\ \vdots \\ v_{NN} \end{pmatrix} \end{pmatrix} \quad (28)$$

$$SV = \begin{pmatrix} \lambda_1 v_{11} & \lambda_2 v_{12} & \dots & \lambda_N v_{1N} \\ \lambda_1 v_{21} & \lambda_2 v_{22} & \dots & \lambda_N v_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ \lambda_1 v_{N1} & \lambda_2 v_{N2} & \dots & \lambda_N v_{NN} \end{pmatrix} \quad (29)$$

Теперь умножим V на диагональную матрицу собственных значений Λ :

$$V\Lambda = \begin{pmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_N \end{pmatrix} \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_N \end{pmatrix} = \begin{pmatrix} \lambda_1 \mathbf{v}_1 & \lambda_2 \mathbf{v}_2 & \dots & \lambda_N \mathbf{v}_N \end{pmatrix} \quad (30)$$

Мы получили то же самое, что и SV

$$SV = V\Lambda \quad (31)$$

Матрица V ортогональная, потому что состоит из собственных векторов, а для любой ортогональной матрицы выполняется $V^{-1} = V^\top$, то есть $VV^\top = V^\top V = I$. Умножим полученное равенство $SV = V\Lambda$ справа на транспонированную матрицу $V^\top$:

$$SVV^\top = V\Lambda V^\top = S \quad (32)$$

Доказали.. идем дальше.

$$\rho'_K = \frac{\sum_{k=1}^K \lambda_k}{\sum_{k=1}^N \lambda_k}.$$

Величина ρ'_K показывает накопленную долю объясненной дисперсии. На практике именно она помогает выбрать число сохраняемых факторов K : мы ищем такой K , при котором существенная часть общей вариации уже объяснена, а дальнейшее добавление компонент дает лишь небольшой выигрыш.

$$F = XV_K, \quad V_K = [v_1, v_2, \dots, v_K].$$

Где V_K - усеченная матрица факторных нагрузок (собственных векторов) размерности $N \times K$. Она формируется путём выделения первых K столбцов из полной ортогональной матрицы собственных векторов V , а $v_1, \dots, v_K$ - отдельные столбцы матрицы V_K - собственные векторы. Каждый вектор v_k имеет размерность $N \times 1$ и содержит веса акций для формирования k -й главной компоненты. F - матрица значений первых K главных компонент размерности $T \times K$. Каждый столбец этой матрицы - ряд значений по дням, который показывает, как в течение T дней рос или падал конкретный рыночный фактор. Эти факторы не дублируют информацию друг друга (их корреляция = 0). Мы объединили их движения N акций и получили K главных независимых рыночных трендов. Домножаем справа на V_K :

$$X \approx FV_K^\top = XV_KV_K^\top.$$

Знак $\approx$ мы не можем поставить, потому что в V мы занулили часть не очень важной информации. Эта запись означает низкоранговую аппроксимацию исходной матрицы доходностей X . Экономически ее можно интерпретировать так: большая часть динамики доходностей объясняется общими факторами, а оставшаяся часть относится к колебаниям отдельных бумаг, их зануляем, оставляем только самое важное.

В вычислительном отношении тому же анализу соответствует сингулярное разложение центрированной матрицы X .

$$X = UDV^\top.$$

Здесь U и V — матрицы левых и правых сингулярных векторов, а D — диагональная матрица сингулярных чисел. Так как X центрирована, PCA и SVD согласованы между собой: собственные значения S выражаются через сингулярные числа:

$$\lambda_k = \frac{d_k^2}{T-1}.$$

Докажем:

$$S = \frac{1}{T-1} X^\top X \quad (33)$$

$$X = UDV^\top \quad (34)$$

$$(UDV^\top)^\top = (V^\top)^\top D^\top U^\top = VD^\top U^\top \quad (35)$$

$$S = \frac{1}{T-1} (VDU^\top) \cdot (UDV^\top) \quad (36)$$

U ортогональна по определению сингулярного разложения, поэтому:

$$U^\top U = I \quad (37)$$

$$S = \frac{1}{T-1}VD(U^\top U)DV^\top = \frac{1}{T-1}VD \cdot DV^\top = V \left(\frac{D^2}{T-1} \right) V^\top = V\Lambda V^\top \quad (38)$$

здесь D^2 - диагональная матрица, элементы главной диагонали d_k^2 , последнюю вкладку я добавила из спектрального разложения. В итоге приравняв получим:

$$\Lambda = \frac{D^2}{T-1} \quad (39)$$

$$\lambda_k = \frac{d_k^2}{T-1} \quad (40)$$

Эта связь важна методически: мы можем работать либо с ковариационной матрицей, либо напрямую с матрицей доходностей, а результат с точки зрения выделения главных компонент будет эквивалентен.

Для нашей работы PCA/SVD выполняет сразу две функции. Первая — статистическая: сокращение размерности и выделение основных источников общего риска. Вторая — содержательная: подготовка структуры, на которой затем строятся факторная регрессия, оценка риск-вкладов и более устойчивая портфельная оптимизация. Именно в этом смысле мы следуем логике [4, 8, 11].

Подробнее про связь МГК и сингулярного разложения:

$$X = U\Sigma V^\top \quad (41)$$

Наибольшие сингулярные числа соответствуют направлениям максимальной дисперсии, значит можно самые важные K сингулярных чисел оставить, а остальное отрезать:

$$\hat{X} = U_K \Sigma_K V_K^\top \quad (42)$$

где U_K - ортогональная матрица $T \times K$, Σ_K - диагональная матрица $K \times K$, V_K - ортогональная матрица $N \times K$. Тогда матрица факторных нагрузок $B = V_K$ (веса активов в выбранных K рыночных факторах) Матрица значений факторов $F = XV_K = U_K \Sigma_K$

Коэффициент детерминации R^2 R^2 вычисляется через отношение дисперсии остатков модели к общей дисперсии зависимой переменной:

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2} \quad (43)$$

где SS_{res} - необъясненная дисперсия, или сумма квадратов остатков регрессионной модели SS_{tot} - общая дисперсия зависимой переменной, вычисляемая как сумма квадратов отклонений фактических значений y_i от их выборочного среднего $\bar{y}$ $\hat{y}_i$ - прогнозируемое значение фактора

Shrinkage Также мы используем метод shrinkage статьи Ледуа-Вольфа из списка литературы. Оценка ковариационной матрицы $\hat{\Sigma}_{LW}$ строится как линейная

комбинация двух матриц:

$$\hat{\Sigma}_{LW} = \delta F + (1 - \delta)S \quad (44)$$

$\delta \in [0, 1]$ - интенсивность сжатия Аналитическое можно найти оптимальный параметр δ - проминимизировав математическое ожидание квадратичной функции потерь (нормы Фробениуса) между оцениваемой матрицей и истинной матрицей ковариаций Σ :

$$\delta^* = \arg \min_{\delta} \mathbb{E} [\|\delta F + (1 - \delta)S - \Sigma\|_F^2] \quad (45)$$

где норма Фробениуса для матрицы A определяется как $\|A\|_F^2 = \text{tr}(A^\top A)$ tr это сумма чисел на главной диагонали

2.4 Матричная регрессия и факторная аппроксимация риска

После выделения факторов нужно перейти к факторной регрессии. Она позволяет выразить доходности активов через общий факторный блок и специфический остаток. Чтоб поставить знак равенства в формуле $X \approx FV_K^\top$, спишем остаток на букву E .

$$X = FB^\top + E.$$

Здесь F — матрица факторов размерности $T \times K$, B — матрица факторных нагрузок размерности $N \times K$, а E — матрица остатков. Строка B_i показывает, насколько i -й актив чувствителен к каждому из выделенных факторов. Чтобы оценить B , занулим E , тк мы не хотим, чтобы случайное E портило оценку трендов B .

$$\hat{B}^\top = (F^\top F)^{-1} F^\top X$$

Вывод этой формулы такой: $F^\top(X - FB^\top) = 0$; $F^\top X - F^\top FB^\top = 0$; $F^\top FB^\top = F^\top X$; $(F^\top F)^{-1}(F^\top F)B^\top = (F^\top F)^{-1}F^\top X$ Это обычная матричная форма оценки коэффициентов методом наименьших квадратов. Метод наименьших квадратов мы используем здесь, чтобы провести линию регрессии между моими факторами F и моими акциями X так, чтобы случайная ошибка E для каждой бумаги была минимальной - найдя веса B факторных нагрузок. Если матрица $F^\top F$ вырождена или если мы хотим записать формулу в более общем виде, удобно использовать псевдообратную матрицу Мура–Пенроуза.

$$\hat{B}^\top = F^+ X.$$

Обозначение F^+ означает псевдообратную матрицу. Именно здесь в нашей теме появляется один из ключевых матричных инструментов, заложенных в первоначальном плане работы.

После оценки нагрузок факторная модель дает естественную аппроксимацию ковариационной матрицы.

$$\hat{\Sigma}^{\text{fact}} = \hat{B} \hat{\Sigma}_f \hat{B}^\top + \hat{D}_\varepsilon$$

Здесь $\hat{\Sigma}_f$ — ковариационная матрица факторов, а $\hat{D}_\varepsilon$ — диагональная матрица дисперсий остатков. Идея этой формулы проста: общий риск описывается через относительно малое число факторов, а индивидуальный риск каждой бумаги остается в отдельном специфическом компоненте. Она есть в работе Chen, B., Huang, S.-F., Pan, G. (2015) High Dimensional Mean-Variance Optimization through Factor Analysis перед уравнением 2.7. Выведем эту формулу:

$$X = F\hat{B}^\top + E \quad (46)$$

Посчитаем ковариацию от обеих частей уравнения:

$$\hat{\Sigma}^{\text{fact}} = \text{Var}(X) = \text{Var}(F\hat{B}^\top + \hat{E}) \quad (47)$$

Оператор ковариации линейный для суммы двух случайных матричных многочленов, разложим верхнее выражение на сумму собственных и перекрестных ковариаций по формуле:

$$\hat{\Sigma}^{\text{fact}} = \text{Var}(F\hat{B}^\top) + \text{Var}(\hat{E}) + 2\text{Cov}(F\hat{B}^\top, \hat{E}) \quad (48)$$

$$2\text{Cov}(F\hat{B}^\top, \hat{E}) = 2M\left((F\hat{B}^\top)^\top \hat{E}\right) = 2M\left(\hat{B}F^\top \hat{E}\right) = 2\hat{B} \cdot M(F^\top \hat{E}) \quad (49)$$

После первого = без вычитания произведения тк $M[E]=0$, B - матрица констант (весов)

Подставим $\hat{E} = X - F\hat{B}^\top$ и $\hat{B}^\top = (F^\top F)^{-1}F^\top X$ $F^\top \hat{E} = F^\top(X - F\hat{B}^\top) = F^\top X - F^\top F\hat{B}^\top = F^\top X - F^\top F(F^\top F)^{-1}F^\top X = F^\top X - I \cdot F^\top X = F^\top X - F^\top X = 0$
Тогда:

$$2\text{Cov}(F\hat{B}^\top, \hat{E}) = 0 \quad (50)$$

Тогда:

$$\begin{aligned} \hat{\Sigma}^{\text{fact}} &= \text{Var}(F\hat{B}^\top) + \text{Var}(\hat{E}) = M\left((F\hat{B}^\top)^\top (F\hat{B}^\top)\right) + \hat{D}_\varepsilon = M\left((\hat{B}^\top)^\top F^\top F\hat{B}^\top\right) + \hat{D}_\varepsilon = \\ &= M\left(\hat{B}F^\top F\hat{B}^\top\right) + \hat{D}_\varepsilon = \hat{B} \cdot M(F^\top F) \cdot \hat{B}^\top + \hat{D}_\varepsilon = \hat{B} \cdot \text{Var}(F) \cdot \hat{B}^\top + \hat{D}_\varepsilon = \hat{B}\hat{\Sigma}_f\hat{B}^\top + \hat{D}_\varepsilon \end{aligned} \quad (51)$$

Здесь $\hat{\Sigma}_f$ - ковариационная матрица факторов, а $\hat{D}_\varepsilon$ - диагональная матрица дисперсий остатков. Идея этой формулы проста: общий риск описывается через относительно малое число факторов, а индивидуальный риск каждой бумаги остается в отдельном специфическом компоненте. Если факторы получены через PCA, то в базовой постановке они ортогональны, а их ковариационная матрица имеет диагональный вид. Это удобно и для интерпретации, и для дальнейшей декомпозиции риска портфеля. С практической точки зрения факторная аппроксимация особенно ценна тогда, когда выборочная ковариационная матрица сама по себе нестабильна или излишне шумна.

2.5 Включение корпоративных характеристик в модель

До этого момента модель была статистической: она опиралась только на цены и доходности. Но тема нашей работы требует включить корпоративные характеристики компаний. Нам важно не просто выделить скрытые факторы риска, но и понять, как особенности фирмы связаны с ожидаемой доходностью и, в расширенной постановке, с ее чувствительностью к факторам. Пусть для каждой компании наблюдается набор из M стандартизованных корпоративных признаков: например, P/E, долговая нагрузка, ROE, рентабельность активов, показатели ликвидности и другие переменные, собранные в матрицу Z размерности $N \times M$.

$$\hat{\mu}^{\text{corp}} = \gamma_0 1_N + Z\gamma$$

$$\begin{pmatrix} \hat{\mu}_1^{\text{corp}} \\ \hat{\mu}_2^{\text{corp}} \\ \vdots \\ \hat{\mu}_N^{\text{corp}} \end{pmatrix} = \begin{pmatrix} \gamma_0 \\ \gamma_0 \\ \vdots \\ \gamma_0 \end{pmatrix} + \begin{pmatrix} z_{11} & z_{12} & \dots & z_{1M} \\ z_{21} & z_{22} & \dots & z_{2M} \\ \vdots & \vdots & \ddots & \vdots \\ z_{N1} & z_{N2} & \dots & z_{NM} \end{pmatrix} \begin{pmatrix} \gamma_1 \\ \gamma_2 \\ \vdots \\ \gamma_M \end{pmatrix} \quad (52)$$

Здесь $\hat{\mu}^{\text{corp}}$ — вектор ожидаемых доходностей, построенный на основе корпоративных характеристик, γ_0 — свободный член, γ — вектор коэффициентов при признаках, 1_N — N -мерный столбец из единиц. В компонентной записи это означает, что каждая ожидаемая доходность выражается через набор признаков соответствующей компании.

$$\hat{\mu}_i^{\text{corp}} = \gamma_0 + \sum_{m=1}^M \gamma_m z_{im}.$$

Такая постановка удобна именно для нашей темы: она делает корпоративный блок не внешним комментарием, а рабочей частью модели портфельного выбора. При этом корпоративные данные должны использоваться с лагом по отношению к доходностям, чтобы избежать look-ahead bias, то есть использования информации, которая в реальном моменте времени еще не была доступна инвестору.

Поскольку исторические средние доходности тоже содержат полезную информацию, разумно рассмотреть комбинированный оценщик ожидаемой доходности.

$$\hat{\mu} = \eta \bar{r} + (1 - \eta) \hat{\mu}^{\text{corp}}, \quad 0 \leq \eta \leq 1.$$

Параметр η регулирует вклад исторической и корпоративной информации. Если η близко к единице, модель больше доверяет выборочным средним доходностям; если η меньше, сильнее используется фундаментальный сигнал из корпоративных показателей.

Расширенная версия модели может быть еще глубже: корпоративные характеристики можно использовать не только для оценки ожидаемых доходностей, но и для объяснения факторных нагрузок. Тогда статистически выделенные факторы получают экономическую интерпретацию.

$$\hat{B} = Z\Gamma + U.$$

Эту формулу мы позаимствовали из работы Fama, French (1992) "The Cross-Section of Expected Stock Returns". Здесь Γ — матрица коэффициентов, связывающая корпоративные признаки с чувствительностью активов к факторам, а U — необъясненная часть нагрузок. Мы не утверждаем, что именно эта расширенная спецификация обязательно будет финальной версией эмпирической модели, но ее включение в теоретический раздел важно: она показывает, как именно статистический и корпоративный блоки могут быть объединены внутри одной конструкции, а не существовать параллельно.

Ridge-регрессия Классический подход к выбору γ предполагает использование метода наименьших квадратов, но финансовые коэффициенты часто сильно линейно зависимы, из-за этого $Z^\top Z$ вырожденной и не получится найти обратную матрицу, что приводит к большим весам в МНК, модель переобучается на историческом шуме. Поэтому мы использовали Ridge-регрессию, которая штрафует функцию потерь МНК за величину коэффициентов квадратом:

$$\hat{\gamma} = \arg \min_{\gamma} (||y - Z\gamma||_2^2 + \lambda ||\gamma||_2^2) \quad (53)$$

Аналитическое решение такое:

$$\hat{\gamma} = (Z^\top Z + \lambda I)^{-1} Z^\top y \quad (54)$$

Хорошо то, что при добавлении λI (как раз наша регуляризация) то что под степенью -1 всегда невырожденно, обратная матрица значит всегда найдется, тк выражение в скобках положительно определено

2.6 Портфельный риск и классическая оптимизация Марковица

Когда вектор ожидаемых доходностей и матрица риска заданы, можно переходить к постановке задачи выбора портфеля. Пусть $w = (w_1, \dots, w_N)^\top$ — вектор долей капитала, инвестируемых в активы. Тогда доходность портфеля в момент t равна линейной комбинации доходностей составляющих бумаг.

$$r_{p,t} = w^\top r_t = \sum_{i=1}^N w_i r_{i,t}$$

$$r_{p,t} = \begin{pmatrix} w_1 & w_2 & \dots & w_N \end{pmatrix} \begin{pmatrix} r_{1,t} \\ r_{2,t} \\ \vdots \\ r_{N,t} \end{pmatrix} \quad (55)$$

Проверка размерностей матриц $(1 \times N) \cdot (N \times 1) = (1 \times 1)$ - на выходе мы получим одно число, доходность портфеля. Соответственно, ожидаемая доходность всего портфеля равна взвешенной сумме ожидаемых доходностей входящих в него акций. Также рядом формула дисперсии портфеля

$$\mu_p = w^\top \mu, \quad \sigma_p^2 = w^\top \Sigma w.$$

Формула для дисперсии — это и есть квадратичная форма Марковица. Она показывает, что портфельный риск зависит не только от волатильности каждой отдельной бумаги, но и от всей ковариационной структуры.

$$\min_w w^\top \Sigma w$$

Базовая задача Марковица состоит в минимизации риска при заданных ограничениях. В нашей постановке естественно использовать следующие условия:

$$1_N^\top w = 1, \quad w^\top \mu \geq \mu_0, \quad w \geq 0.$$

Первое ограничение означает что бюджет распределяется полностью, второе — требование к минимально допустимой ожидаемой доходности μ_0 , третье - запрет на короткие позиции (тк при продаже на короткой позиции у нас $r_i < 0$, тогда и вес < 0). В зависимости от эмпирической постановки последнее ограничение можно убрать, но для учебной задачи вариант без коротких продаж выглядит более аккуратным.

Если ограничение $w \geq 0$ опустить и предположить, что матрица Σ невырождена, эффективная граница допускает аналитическое описание. Для этого вводятся стандартные вспомогательные величины:

$$\begin{aligned} A &= 1_N^\top \Sigma^{-1} 1_N, \quad B = 1_N^\top \Sigma^{-1} \mu, \quad C = \mu^\top \Sigma^{-1} \mu, \quad \Delta = AC - B^2. \\ A &= 1_N^\top \Sigma^{-1} 1_N = \\ &= \begin{pmatrix} 1 & 1 & \dots & 1 \end{pmatrix} \begin{pmatrix} \sigma^{11} & \sigma^{12} & \dots & \sigma^{1N} \\ \sigma^{21} & \sigma^{22} & \dots & \sigma^{2N} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma^{N1} & \sigma^{N2} & \dots & \sigma^{NN} \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} = \\ &= \sum_{i=1}^N \sum_{j=1}^N \sigma^{ij} \end{aligned} \tag{56}$$

$$\begin{aligned}
B &= 1_N^\top \Sigma^{-1} \mu = \\
&= \begin{pmatrix} 1 & 1 & \dots & 1 \end{pmatrix} \begin{pmatrix} \sigma^{11} & \sigma^{12} & \dots & \sigma^{1N} \\ \sigma^{21} & \sigma^{22} & \dots & \sigma^{2N} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma^{N1} & \sigma^{N2} & \dots & \sigma^{NN} \end{pmatrix} \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_N \end{pmatrix} = \\
&= \sum_{i=1}^N \sum_{j=1}^N \sigma^{ij} \mu_j
\end{aligned} \tag{57}$$

$$\begin{aligned}
C &= \mu^\top \Sigma^{-1} \mu = \\
&= \begin{pmatrix} \mu_1 & \mu_2 & \dots & \mu_N \end{pmatrix} \begin{pmatrix} \sigma^{11} & \sigma^{12} & \dots & \sigma^{1N} \\ \sigma^{21} & \sigma^{22} & \dots & \sigma^{2N} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma^{N1} & \sigma^{N2} & \dots & \sigma^{NN} \end{pmatrix} \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_N \end{pmatrix} = \\
&= \sum_{i=1}^N \sum_{j=1}^N \sigma^{ij} \mu_i \mu_j
\end{aligned} \tag{58}$$

$$\Delta = AC - B^2 = \left(\sum_{i=1}^N \sum_{j=1}^N \sigma^{ij} \right) \left(\sum_{i=1}^N \sum_{j=1}^N \sigma^{ij} \mu_i \mu_j \right) - \left(\sum_{i=1}^N \sum_{j=1}^N \sigma^{ij} \mu_j \right)^2 \tag{59}$$

Проверка размерностей для этих всех уравнений $(1 \times N) \cdot (N \times N) \cdot (N \times 1) = 1 \times 1$ подтверждает, что в каждом случае результатом операции является число. Эти величины представляют собой комбинации матрицы риска и вектора доходностей. Через них удобно записываются веса эффективного портфеля при заданном целевом уровне доходности μ_0 .

$$w(\mu_0) = \left(\frac{C - \mu_0 B}{\Delta} \right) \Sigma^{-1} 1_N + \left(\frac{\mu_0 A - B}{\Delta} \right) \Sigma^{-1} \mu.$$

Формула оптимальных весов $w(\mu_0)$ является аналитическим решением задачи оптимизации методом множителей Лагранжа. Для классической задачи Марковица функция Лагранжа имеет вид:

$$L(w, \lambda_1, \lambda_2) = \frac{1}{2} w^\top \Sigma w - \lambda_1 (1_N^\top w - 1) - \lambda_2 (\mu^\top w - \mu_0) \tag{60}$$

где λ_1 и λ_2 - множители Лагранжа для бюджетного ограничения и ограничения на целевую доходность соответственно. Берем производную по вектору весов w и приравняем к 0, получаем:

$$\frac{\partial L}{\partial w} = \Sigma w - \lambda_1 1_N - \lambda_2 \mu = 0 \tag{61}$$

$$w^* = \Sigma^{-1} (\lambda_1 1_N + \lambda_2 \mu) \tag{62}$$

Хотим найти λ_1 и λ_2 , подставим полученное w^* в систему ограничений портфеля:

$$\begin{cases} 1_N^\top \Sigma^{-1} 1_N \lambda_1 + 1_N^\top \Sigma^{-1} \mu \lambda_2 = 1 \\ \mu^\top \Sigma^{-1} 1_N \lambda_1 + \mu^\top \Sigma^{-1} \mu \lambda_2 = \mu_0 \end{cases} \quad (63)$$

тк $\mu^\top \Sigma^{-1} 1_N = 1_N^\top \Sigma^{-1} \mu$ Решим методом Крамера относительно λ_1 и λ_2 , находим их явный вид и определитель $\Delta = AC - B^2$:

$$\lambda_1 = \frac{C - \mu_0 B}{\Delta}, \quad \lambda_2 = \frac{\mu_0 A - B}{\Delta} \quad (64)$$

Подставим λ_1 и λ_2 обратно в уравнение с весами, мы вывели формулу оптимальных весов портфеля:

$$w(\mu_0) = \left(\frac{C - \mu_0 B}{\Delta} \right) \Sigma^{-1} 1_N + \left(\frac{\mu_0 A - B}{\Delta} \right) \Sigma^{-1} \mu \quad (65)$$

С вычислительной точки зрения формула показывает ахиллесову пятую модели Марковица. Как видно, итоговые веса активов w почти полностью зависят от обратной ковариационной матрицы Σ^{-1} . Операция обращения матриц чувствительна к качеству матрицы. Если исходная матрица рисков Σ оценена неточно или содержит статистический шум, при ее обращении эти ошибки многократно усиливаются. В результате формула начинает выдавать нестабильные или экстремальные веса активов. Именно поэтому качество оценки Σ настолько критично. Если Σ оценена плохо, то и веса w оказываются нестабильными.

$$\sigma_p^2(\mu_0) = \frac{A\mu_0^2 - 2B\mu_0 + C}{\Delta}.$$

Так задается эффективная граница в координатах «ожидаемая доходность — риск». В эмпирической части мы будем использовать эту классическую конструкцию как базовую точку сравнения для более устойчивых и более риск-ориентированных постановок.

Эту формулу мы уже вводили выше, но домножим справа на w и слева на w^T :

$$\hat{\Sigma}^{\text{fact}} = \hat{B} \hat{\Sigma}_f \hat{B}^\top + \hat{D}_\varepsilon.$$

$$\sigma_p^2 = w^\top \hat{\Sigma}^{\text{fact}} w = w^\top \left(\hat{B} \hat{\Sigma}_f \hat{B}^\top \right) w + w^\top \hat{D}_\varepsilon w \quad (66)$$

$$\begin{aligned} w^\top \left(\hat{B} \hat{\Sigma}_f \hat{B}^\top \right) w &= w^\top \left(\sum_{k=1}^K \lambda_k v_k v_k^\top \right) w = \\ &= \sum_{k=1}^K \lambda_k (w^\top v_k) (v_k^\top w) \end{aligned} \quad (67)$$

Учтем

$$(w^\top v_k)^\top = v_k^\top (w^\top)^\top = v_k^\top w = w^\top v_k \quad (68)$$

$$\sum_{k=1}^K \lambda_k (w^\top v_k) (v_k^\top w) = \sum_{k=1}^K \lambda_k (w^\top v_k)^2 \quad (69)$$

$$\sigma_p^2 \approx \sum_{k=1}^K \lambda_k (w^\top v_k)^2 + w^\top D_\varepsilon w$$

В факторной модели риск портфеля можно также разложить по источникам. Если факторы получены из PCA и ортогональны, то основная часть дисперсии портфеля связана с экспозициями к главным компонентам, а остаточный блок отвечает за специфический риск. Здесь λ_k — собственные значения, v_k — собственные векторы ковариационной матрицы, а D_ε — диагональная матрица остаточных дисперсий. Эта формула особенно полезна интерпретационно: она позволяет увидеть, какие статистические факторы дают наибольший вклад в риск оптимального портфеля. Распишу через суммы для наглядности:

$$\begin{aligned} \sigma_p^2 \approx \sum_{k=1}^K \lambda_k \left[\begin{pmatrix} w_1 & w_2 & \dots & w_N \end{pmatrix} \begin{pmatrix} v_{1,k} \\ v_{2,k} \\ \vdots \\ v_{N,k} \end{pmatrix} \right]^2 + \\ + \begin{pmatrix} w_1 & w_2 & \dots & w_N \end{pmatrix} \begin{pmatrix} \sigma_{\varepsilon,1}^2 & 0 & \dots & 0 \\ 0 & \sigma_{\varepsilon,2}^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_{\varepsilon,N}^2 \end{pmatrix} \begin{pmatrix} w_1 \\ w_2 \\ \vdots \\ w_N \end{pmatrix} \end{aligned} \quad (70)$$

$$\sigma_p^2 \approx \sum_{k=1}^K \lambda_k \left(\sum_{i=1}^N w_i v_{i,k} \right)^2 + \sum_{i=1}^N w_i^2 \sigma_{\varepsilon,i}^2 \quad (71)$$

Также скажем про коэффициент Sharpe: он позволяет определить величину избыточной доходности, которую инвестор получает на единицу принятого риска.

$$SR = \frac{R_p - R_f}{\sigma_p} \quad (72)$$

R_f - безрисковая ставка доходности, в качестве нее обычно принимается доходность государственных облигаций сопоставимого срока обращения. Более высокое значение коэффициента показывает более эффективное управление портфелем. $SR > 1$ означает высокое качество инвестиционной стратегии, полученная доходность полностью компенсирует принятый инвестором риск. $SR < 0$ указывает на неэффективность управления, так как доходность портфеля уступает доходности альтернативных безрисковых инструментов.

2.7 VaR, ES и CVaR-оптимизация

Классическая дисперсия хорошо работает как мера общей вариативности, но она не показывает, насколько тяжелыми могут быть потери в неблагоприятных состояниях рынка. Поэтому для нашей темы важен дополнительный блок квантильных и хвостовых мер риска. Пусть $L_t = -r_{p,t}$ — потери портфеля в момент t . Тогда Value-at-Risk на уровне доверия β определяется как соответствующий квантиль распределения потерь.

$$VaR_\beta(L) = \inf\{l \in \mathbb{R} : P(L \leq l) \geq \beta\}$$

Если, например, $\beta = 0,95$, то $VaR_{0,95}$ — это такой уровень потерь, который с вероятностью 95% не будет превышен. Недостаток этой меры состоит в том, что она говорит только о пороге, но ничего не сообщает о средней величине потерь за этим порогом.

$$ES_\beta(L) = E[L \mid L \geq VaR_\beta(L)].$$

Expected Shortfall (или CVaR, одно и то же) показывает среднее потерь в худшей части распределения. Именно поэтому ES лучше согласуется с задачей анализа стрессовых ситуаций и хвостового риска [6].

Если потери отсортированы по возрастанию $L_{(1)} \leq L_{(2)} \leq \dots \leq L_{(T)}$, а $m = \lceil \beta T \rceil$, можно использовать следующие эмпирические аналоги.

$$\widehat{VaR}_\beta = L_{(m)}, \quad \widehat{ES}_\beta = \frac{1}{T - m + 1} \sum_{j=m}^T L_{(j)}.$$

Первая величина дает эмпирический квантиль, вторая — среднее значение потерь в правом хвосте выборочного распределения, берем последние потери, которые входят в долю $1 - \beta$, делим на их колво. Именно правый хвост распределения L показывает наибольшие убытки. На практике именно по таким формулам удобно сравнивать риск портфелей, полученных разными способами.

Для нашей работы особенно важна оптимизационная форма Rockafellar–Uryasev [7], поскольку она позволяет включить CVaR непосредственно в задачу выбора портфеля.

$$F_\beta(w, \alpha) = \alpha + \frac{1}{(1 - \beta)T} \sum_{t=1}^T \max\{L_t(w) - \alpha, 0\}.$$

Подходит для одновременного поиска оптимальных весов портфеля и расчета меры риска CVaR. Здесь мы регулируем α , w . Максимум $\max\{L_t(w) - \alpha, 0\}$ играет роль фильтра: если в день t убыток портфеля оказался меньше, то сценарий обнуляется, а если убыток превысил порог, то в сумму засчитывается только величина этого превышения. Элемент $(1)T$ в знаменателе нормирует полученную сумму на количество наблюдений, попавших в наихудший хвост распределения при заданном уровне

доверия. α - это временная граница хвоста распределения (то есть приближение VaR), если мы поставим ее очень большой, убытки плохо будут переходить порог, правая часть занулится и останется большая α . Если поставим очень маленькое α , левая часть станет очень маленькой, тогда слишком много убытков накопится из-за суммы слева. Тоже не минимум функции. Функция выпукла (при α стремящемся к $+\infty$ или к 0 - функция улетает в края вверх), это облегчает сильно задачу оптимизации. Минимизация функции F_β по w и α приводит к портфелю с минимальным CVaR, а минимум равен минимальному CVaR.

$$\min_{w, \alpha, u_t} \alpha + \frac{1}{(1 - \beta)T} \sum_{t=1}^T u_t$$

Эквивалентная вычислительная постановка имеет вид линейно-ограниченной задачи:

$$u_t \geq L_t(w) - \alpha, \quad u_t \geq 0, \quad 1_N^\top w = 1, \quad w^\top \mu \geq \mu_0, \quad w \geq 0.$$

Переобозначили максимум на u_t - они отвечают за превышение потерь над уровнем α . Эта запись делает CVaR-оптимизацию практически реализуемой и позволяет сопоставить портфели, минимизирующие дисперсию, с портфелями, минимизирующими хвостовой риск. Содержательно это означает следующее. В нашей курсовой работе variance-блок и ES/CVaR-блок не конкурируют друг с другом, а решают разные задачи. Дисперсия нужна для описания общей ковариационной структуры и эффективной границы, тогда как ES нужен для проверки того, насколько эта конструкция устойчива к большим неблагоприятным отклонениям.

2.8 Как объединяются три подхода в единой схеме

Перед содержательным обсуждением удобно зафиксировать объединяющую схему в компактной табличной форме.

Таблица 3. Как разные блоки складываются в одну исследовательскую схему

Блок модели	Что он описывает	Инструменты
Статистический факторный блок	Выделение общих рыночных движений и уменьшение размерности	PCA/SVD, факторная регрессия, факторная ковариация
Корпоративный блок	Экономическая интерпретация и оценка ожидаемой доходности	P/E, долговая нагрузка, ROE и другие признаки в матрице Z
Риск-оптимизационный блок	Переход от описания данных к выбору портфеля и контролю хвостовых потерь	Марковиц, VaR, ES, CVaR

Теперь можно явно сформулировать, как в нашей работе объединяются три подхода, о которых было сказано во введении и в обзоре литературы.

Первый блок — статистический. Он начинается с матрицы доходностей X и через ковариационную матрицу S , PCA и SVD приводит нас к факторам F и нагрузкам B . Его задача — описать общие движения рынка, уменьшить размерность и получить устойчивую структуру систематического риска. Без этого шага оптимизация портфеля в многомерной задаче слишком зависит от шумных ковариационных оценок.

Второй блок — корпоративный. Он строится на матрице признаков Z и позволяет оценить вектор ожидаемых доходностей μ либо, в расширенной версии, объяснить часть факторных нагрузок B через характеристики компаний. Этот блок отвечает за экономический смысл модели. Если оставить только PCA, мы получим статистически сильные, но не всегда интерпретируемые компоненты. Корпоративные характеристики позволяют понять, какие именно свойства компаний связаны с повышенной доходностью или с повышенной чувствительностью к общим факторам.

Третий блок — риск-оптимизационный. На его вход поступают уже не исходные цены, а оценки μ и Σ , полученные после факторного и корпоративного анализа. Далее строятся портфели по Марковицу и портфели с контролем хвостового риска через ES/CVaR. Этот блок нужен для того, чтобы перевести модель из описательной формы в прикладную: не просто объяснить структуру риска, а показать, как она меняет состав оптимального портфеля.

Почему мы ожидаем хороший результат именно от такой комбинации? Потому что слабые места одного подхода компенсируются сильными сторонами другого. Факторная модель снижает размерность, но ей не хватает экономической интерпретации — ее дает корпоративный блок. Корпоративный блок может быть содержательно богатым, но без факторной и ковариационной структуры он не отвечает на вопрос о совместном риске активов. Модель Марковица дает ясную оптимизационную рамку, но при использовании только дисперсии может недооценивать пессимистичные сценарии — этот недостаток исправляют ES и CVaR. Иными словами, связка методов нужна не ради сложности как таковой, а ради содержательной полноты и вычислительной устойчивости.

В окончательной рабочей схеме порядок действий можно описать так. Сначала из ценовых данных строятся доходности и оценивается ковариационная структура. Затем через PCA/SVD выделяются статистические факторы и строится факторная аппроксимация матрицы риска. Параллельно из корпоративной отчетности собираются фирменные показатели и формируется оценка ожидаемой доходности. После этого обе части соединяются в оптимизационной задаче: variance-постановке Марковица и ES/CVaR-постановке для анализа хвостовых потерь. Наконец, результаты сравниваются между собой по структуре весов, уровню риска и устойчивости к экстремальным движениям рынка

3 ЭМПИРИЧЕСКАЯ ПРОВЕРКА

Эмпирическая часть строится как продолжение теоретической постановки, а не как отдельный расчет. Сначала формируется матрица дневных доходностей по акциям Московской биржи, затем оцениваются ковариации, корреляции и РСА-факторы, после этого добавляется корпоративная матрица признаков и строятся портфельные стратегии. В конце результаты проверяются на периоде, который не использовался для статического формирования весов.

В работе используется фиксированный кандидатный пул из 25 бумаг. Такой подход нужен для ограничения подгонки: мы заранее задаем список активов и применяем к ним единый фильтр покрытия, а не отбираем только те бумаги, которые постфактум дали удобный результат. В выборку входят банки и финансовые компании, нефтегазовый сектор, металлы и добыча, электроэнергетика, телекоммуникации, потребительский сектор, транспорт и химия.

Таблица 4. Кандидатный пул бумаг для эмпирической проверки

Секторный блок	Тикеры
Банки и финансы	SBER, VTBR, MOEX
Нефть и газ	GAZP, LKOH, ROSN, NVTK, TATN, SNGS
Металлы и добыча	GMKN, PLZL, ALRS, NLMK, MAGN, CHMF, RUAL
Электронергетика	IRAO, HYDR, FEES
Телекоммуникации и холдинги	MTSS, RTKM, AFKS
Потребительский сектор и транспорт	MGNT, AFLT
Химия	PHOR

Ценовые данные берутся в формате дневных свечей OHLCV. В расчетах используется цена закрытия, по которой строятся логарифмические доходности. Остальные поля сохраняются в исходной таблице: объем торгов нужен для контроля ликвидности, а диапазон high-low может использоваться как вспомогательная характеристика рыночного поведения бумаги.

Ключевой принцип корпоративного блока – правило *as-of*. Корпоративный показатель может использоваться только после даты, когда он был доступен инвестору. В ноутбуке это реализовано через поле `available_from`; если дата не задана вручную, годовая отчетность за год Y считается доступной с 1 июля года $Y + 1$. Поэтому при формировании портфеля на 03.01.2024 используются корпоративные данные, доступные к этой дате, а не вся будущая панель.

Проверка проводится в двух режимах. Первая проверка статическая: веса оцениваются на обучающем периоде 2019–2023 гг. и фиксируются на проверочном периоде 2024–2025 гг. Вторая проверка rolling-window: модель последовательно обнов-

ляет обучающую выборку, данные о состоянии компании и веса, после чего проверяет доходность на следующем квартальном окне. Такое разделение важно, потому что статистический тест показывает качество одной выбранной спецификации, а rolling-window ближе к практическому использованию портфельной системы.

В качестве метрик используются годовая доходность, годовая волатильность, коэффициент Sharpe при нулевой безрисковой ставке, дневные VaR 95% и ES 95%, максимальная просадка и ННІ для весов (индекс Херфиндаля-Хиршмана, сумма квадратов всех весов). Равновзвешенный портфель Equal используется как базовый ориентир. Это принципиально: сложная модель должна сравниваться не только с другими оптимизаторами, но и с простым правилом, которое не зависит от оценки ковариаций и средних доходностей

4 РАСЧЕТНАЯ СПЕЦИФИКАЦИЯ МОДЕЛИ И ДАННЫЕ

Практическая часть реализована в Jupyter Notebook. Расчетный контур включает загрузку OHLCV-данных, фильтрацию покрытия, построение матрицы доходностей, расчет описательных статистик, оценку ковариаций и корреляций, PCA/МПК, построение корпоративной матрицы, формирование портфелей и проверку результатов на статическом и rolling-window периодах.

После фильтра покрытия не ниже 95% в рабочей выборке осталось 25 бумаг из 25 кандидатных тикеров. Матрица цен закрытия имеет размер 1777×25 , а матрица дневных логарифмических доходностей - 1776×25 . Основное обучающее окно содержит 1226 дневных наблюдений, а проверочное окно 2024-2025 гг. - 550 наблюдений.

Таблица 5. Основные параметры расчетной выборки

Параметр	Значение
Число тикеров после фильтра покрытия	25
Порог покрытия торговых дат	95%
Размер матрицы цен закрытия	1777×25
Размер матрицы логарифмических доходностей	1776×25
Обучающий период	03.01.2019–29.12.2023
Число дневных наблюдений в train	1226
Проверочный период	03.01.2024–30.12.2025
Число дневных наблюдений в test	550
Дата формирования статического портфеля	03.01.2024

Далее строится матрица доходностей

$$r_{ti} = \ln \frac{P_{ti}}{P_{t-1,i}}, \quad R = (r_{ti}),$$

где P_{ti} – цена закрытия бумаги i в день t . На обучающем окне рассчитываются средние доходности, выборочная ковариация S , корреляционная матрица и PCA-разложение. Годовые показатели приводятся к дневным умножением математического ожидания на 252 (среднее количество торговых дней в году), а стандартного отклонения - на $\sqrt{252}$.

Корпоративная часть строится по annual CSV за 2019-2024 гг. В базовый набор признаков входят рыночная капитализация, P/E, P/B, ROE, Debt/Equity, NetDebt/EBITDA, дивидендная доходность и доля акций в свободном обращении. Из-за отсутствия наблюдений Debt/Equity в итоговой спецификации используется набор из семи признаков: `log_market_cap`, `pe`, `pb`, `roe`, `netdebt_ebitda`, `dividend_yield`, `free_float`. На дату статического формирования портфеля корпоративная панель, доступная по правилу *as-of*, содержит 100 наблюдений формата ticker-year за 2019-2022 гг.; база данных для ранжирования содержит 25 компаний и 7 признаков.

Перед использованием признаки винзоризируются (усекаем экстремальные значения, но не удаляем, а приравниваем к порогу) и стандартизируются:

$$z_{im}^{std} = \frac{z_{im} - \bar{z}_m}{s_m}.$$

Стандартизация нужна потому, что признаки измеряются в разных единицах: капитализация - в рублях, P/E и P/B - в относительных коэффициентах, дивидендная доходность и free float - в долях или процентах, тк это доля акций в свободном обращении.

В корпоративном блоке веса признаков рассчитываются как комбинация трех элементов: абсолютной величины ridge-коэффициента, вклада признака в корпоративную PCA-структуру и временной устойчивости. Наибольший итоговый вес получил показатель P/B - 20.99%, затем дивидендная доходность - 17.77% и NetDebt/EBITDA - 16.27%. Эти веса не трактуются как причинные эффекты; они используются как способ сформировать более устойчивый корпоративный сигнал и объяснить статистические факторы.

Таблица 6. Итоговые веса корпоративных признаков

Признак	Ridge-вес	Итоговый вес	Знак в скоринге
P/B	0.296	0.210	+
Дивидендная доходность	0.221	0.178	+
NetDebt/EBITDA	0.186	0.163	—
Логарифм капитализации	0.151	0.139	+
P/E	0.074	0.111	+
Free float	0.022	0.104	—
ROE	0.049	0.096	+

Портфельные стратегии строятся только для покупки акций, короткие позиции запрещены, сумма весов равна единице, нижняя граница веса равна нулю. Верхнее ограничение на вес отдельной бумаги составляет 25%, а для менее ликвидных бумаг применяется более жесткий лимит. В сравнение включаются четыре группы стратегий:

- базовая равновзвешенная стратегия **Equal** — берется весь доступный капитал и делится поровну между всеми 25 компаниями. Вес каждой бумаги равен 4%
- риск-стратегии:
 - MinVar_sample** — классический портфель Марковица, который минимизирует общую дисперсию портфеля
 - MinVar_LW** — тоже портфель минимальной дисперсии на матрице Ledoit-Wolf, сжали просто ковариационную матрицу S
 - MinVar_factor** — матрица ковариаций собирается через PCA, модель выделяет K главных рыночных факторов
 - MinCVaR** — минимизируем CVaR по методу Рокафеллара–Урясева
- корпоративные и гибридные стратегии:
 - CorpSignal_Top** — портфель из топ-акций по фундаментальным показателям
 - CorpTilt_MV** — за основу берется хороший по риску портфель **MinVar_LW**, но его веса смещаются в сторону компаний с отличными фундаментальными показателями
 - Hybrid_MV_PCA_Corp** — пытаемся объединить всё лучшее сразу: берем факторные ковариации из PCA, оцениваем риски через Ледуа-Вулфа и накладываем на них фильтр с корпоративными факторами
 - Ensemble_StatPriority** — комбинация моделей вес стратегии внутри ансамбля распределяется на основе её исторической надежности
- итоговая стратегия **Final_Recommended_Portfolio**.

Итоговый портфель выбирается через внутреннюю multi-window validation на train-периоде, где окна 2021, 2022 и 2023 гг. используются как псевдо-test. В результате выбран кандидат LW85_CVaR15: 85% веса риск-ядра MinVar_LW и 15% CVaR-компоненты.

5 ЭМПИРИЧЕСКАЯ ЧАСТЬ: РАСШИРЕННАЯ ВЫБОРКА, КОРПОРАТИВНЫЕ ПРИЗНАКИ И ПОРТФЕЛЬНАЯ ПРОВЕРКА

В этом разделе теоретическая схема проверяется на фактических расчетах. Мы последовательно рассматриваем описательную статистику, корреляционную структуру, PCA/МПК, устойчивость ковариационных оценок, корпоративный блок и результаты портфельных стратегий.

5.1 Описательная статистика и неоднородность доходностей

Описательная статистика показывает неоднородность бумаг по риску. На обучающем периоде 2019-2023 гг. наиболее волатильными среди первых строк таблицы оказались VTBR, SNGS, GAZP, IRAO, TATN и SBER: их годовая волатильность находится близко к 40% или превышает. При этом высокая волатильность не означает высокую среднюю доходность. Например, у VTBR и AFLT на обучающем окне средняя годовая доходность отрицательна, несмотря на высокую изменчивость.

Такая картина подтверждает, что выбор портфеля нельзя строить только по исторической доходности. Для части бумаг характерны асимметрия и высокий избыточный эксцесс, то есть распределение доходностей имеет тяжелые хвосты. Поэтому в дальнейших расчетах используются не только волатильность и Sharpe, но и VaR 95%, ES 95% и максимальный убыток.




Рисунок 1. Нормированные цены закрытия по расширенной выборке

5.2 Корреляционная структура и PCA/МГК

Корреляционная структура расширенной выборки достаточно плотная: средняя попарная корреляция равна 0.484, медианная - 0.493, минимальная - 0.078, максимальная - 0.794. Это означает, что формальное наличие 25 бумаг не устраняет общий рыночный риск. Большая часть активов движется совместно, особенно в пределах близких секторных групп.

Таблица 7. Сводка корреляционной структуры на обучающем окне

Показатель	Значение
Средняя попарная корреляция	0.484
Медианная попарная корреляция	0.493
Минимальная попарная корреляция	0.078
Максимальная попарная корреляция	0.794




Рисунок 2. Корреляционная матрица доходностей

РСА/МГК подтверждает наличие сильного общего фактора. Первая главная компонента объясняет 53.17% дисперсии доходностей, а первые шесть компонент — 71.29%. Поэтому в факторной части модели выбрано $K = 6$: этот уровень покрывает основную часть вариации и при этом не превращает факторную модель в почти полную копию исходной ковариационной матрицы.

Таблица 8. Доля дисперсии, объясненная первыми РСА-компонентами

Компонента	Доля дисперсии	Накопленная доля
PC1	53.17%	53.17%
PC2	4.71%	57.88%
PC3	4.45%	62.33%
PC4	3.37%	65.69%
PC5	2.88%	68.58%
PC6	2.71%	71.29%




Рисунок 3. PCA: индивидуальная и накопленная доля объясненной дисперсии

Здесь сложно экономически интерпретировать. PC1 трактуется как общий рыночный фактор, потому что он объясняет больше половины дисперсии. Остальные компоненты могут отражать секторные различия и специфические группы бумаг, но это не задается заранее. Поэтому далее мы используем корпоративную матрицу Z для объяснения PCA-нагрузок

5.3 Факторная ковариация и Ledoit-Wolf shrinkage

После PCA сравниваются три оценки матрицы риска: выборочная ковариация, факторная аппроксимация через шесть компонент и Ledoit–Wolf оценка. Факторная ковариация имеет относительную ошибку Фробениуса 0.064 относительно выборочной матрицы, а Ledoit–Wolf – 0.094. Коэффициент shrinkage равен 0.100. Эти значения показывают, что регуляризация не полностью меняет структуру риска, но сглаживает ее и делает более пригодной для оптимизации.

Таблица 9. Сравнение оценок ковариационной матрицы

Оценка ковариации	Ошибка Фробениуса к sample	Shrinkage
Sample	0.000	–
PCA-factor, $K = 6$	0.064	–
Ledoit–Wolf	0.094	0.100

Для портфельной логики важен не только размер ошибки к выборочной матрице. Выборочная матрица сама по себе не является истинной: она только базовая точка сравнения. Поэтому качество Ledoit–Wolf и факторной оценки оценивается дальше через веса и out-of-sample метрики. Именно поэтому MinVar_LW в работе рассматривается как риск-ядро, а не как самостоятельное доказательство улучшения доходности.

5.4 Корпоративные признаки и PCA-нагрузки

Корпоративный блок в модели решает две основные задачи. Первая — оценка ожидаемой доходности акций на основе их фундаментальных показателей. Вторая — экономическая интерпретация факторных нагрузок метода главных компонент (Λ). Регрессионный анализ показывает, что корпоративные характеристики хорошо объясняют природу только первых трех главных компонент: коэффициент детерминации R^2 для PC1 составляет 0.392, для PC2 - 0.546, а для PC3 - 0.325. Для компонент PC4-PC6 связь с фундаментальными показателями практически отсутствует. Это означает, что первым трем факторам можно дать четкое экономическое обоснование, тогда как последующие компоненты интерпретировать практически невозможно.

Таблица 10. Объяснение PCA-нагрузок корпоративными признаками

Компонента	R^2	Ridge α
PC1	0.392	25.119
PC2	0.546	10.000
PC3	0.325	15.849
PC4	0.004	1000.000
PC5	0.022	1000.000
PC6	0.007	1000.000

PCA действительно выделяет статистические направления, но не все из них одинаково хорошо связаны с корпоративными характеристиками. Поэтому мы не утверждаем, что каждая компонента имеет ясный экономический смысл. Только первые компоненты можно частично интерпретировать через размер, оценку, долговую нагрузку, дивидендность и free float, а уже для остальных необъяснённых компонент какая-либо сильная логическая связь с корпоративными показателями отсутствует.

5.5 Статическая проверка 2024–2025 гг.

В статическом out-of-sample тесте веса оцениваются на train-периоде 2019–2023 гг. и фиксируются на 2024–2025 гг. Большинство стратегий на этом периоде имеют отрицательную годовую доходность. Поэтому главный вопрос здесь не в том, удалось ли получить положительную доходность на неблагоприятном рынке, а в том, снижает ли модель потери и риск относительно равновзвешенного портфеля.

Таблица 11. Портфельные метрики на статическом test 2024–2025 гг.

Стратегия	Доходность, год	Волатильность, год	Sharpe	VaR 95%, день	ES 95%, день	Max drawdown	NHI
Equal	-8.94%	23.78%	-0.376	2.70%	3.37%	-38.43%	0.040
MinVar sample	-3.18%	22.72%	-0.140	2.50%	3.28%	-36.93%	0.141
MinVar LW	-4.14%	22.70%	-0.182	2.55%	3.28%	-37.13%	0.117
MinVar factor	-3.51%	22.48%	-0.156	2.42%	3.23%	-36.47%	0.141
MinCVaR	-3.18%	22.72%	-0.140	2.50%	3.28%	-36.93%	0.141
CorpSignal Top	-1.06%	22.76%	-0.047	2.39%	3.21%	-31.82%	0.096
CorpTilt MV	-0.13%	22.76%	-0.006	2.50%	3.22%	-32.49%	0.133
Hybrid MV PCA Corp	-3.37%	22.50%	-0.150	2.55%	3.24%	-36.06%	0.118
Ensemble StatPriority	-2.60%	22.49%	-0.116	2.54%	3.23%	-35.43%	0.119
Final Recommended	-4.00%	22.70%	-0.176	2.54%	3.28%	-37.10%	0.120

По Sharpe лучшей в статическом test оказалась стратегия **CorpTilt_MV**: ее Sharpe равен -0.006, а годовая доходность – около -0.13%. Это все еще не положительный устойчивый результат, но на фоне **Equal** с доходностью -8.94% и Sharpe -0.376 корпоративный tilt заметно снижает потери. **Final_Recommended_Portfolio**, выбранный внутренней validation-процедурой, показывает годовую доходность -4.00%, Sharpe -0.176 и максимальную просадку -37.10%. Он лучше равных весов по доходности и Sharpe, но уступает **CorpTilt_MV** в данном статическом окне.




Рисунок 4. Статический test 2024–2025: итоговый портфель против Equal и риск-стратегий

Отдельно по эффективности относительно **Equal** лучший интегральный результат также показывает **CorpTilt_MV**: $\Delta Sharpe = +0.370$, прирост годовой доходности к **Equal** равен 8.81 п.п., а efficiency score равен 0.865. Этот результат поддерживает включение корпоративных признаков, но не доказывает универсальное превосходство корпоративного блока: проверка относится к конкретному периоду 2024–2025 гг.

5.6 Rolling-window проверка

Rolling-window блок имитирует практическое обновление портфеля. На каждом окне train берется от 2019 года до дня перед началом текущего test-окна, корпоративные данные фильтруются по `available_from <= decision_date`, после чего портфельные веса пересчитываются и применяются к следующему 63-дневному окну. Всего в production rolling-window получилось 9 проверочных окон за 2024–2025 гг.

Таблица 12. Сводка rolling-window результатов 2024–2025 гг.

Стратегия	Средний Sharpe	Медианный Sharpe	Средняя доходность, год	Средняя max drawdown	Окна
MinVar LW	0.751	-0.134	5.51%	-11.94%	9
Final Recommended	0.751	-0.136	5.55%	-11.93%	9
MinCVaR	0.747	-0.168	5.70%	-11.87%	9
MinVar sample	0.747	-0.168	5.70%	-11.87%	9
MinVar factor	0.722	-0.202	5.48%	-11.77%	9
Hybrid MV PCA Corp	0.712	-0.154	5.25%	-11.87%	9
Ensemble StatPriority	0.669	-0.169	4.92%	-11.77%	9
CorpTilt MV	0.511	-0.225	3.02%	-12.08%	9
Equal	0.425	-0.108	-0.39%	-12.12%	9
CorpSignal Top	0.258	-0.140	-0.56%	-11.16%	9

Результаты тестирования в режиме скользящего окна (*rolling-window*) отличаются от статического теста. Наивысший средний коэффициент Шарпа демонстрирует стратегия MinVar_LW (0.751). Итоговый портфель Final_Recommended_Portfolio показывает практически идентичные результаты как по скорректированной на риск, так и по средней доходности. Это говорит о том, что при регулярной ребалансировке портфеля качество математической оценки рисков (матрица Ледуа-Вулфа) играет более важную роль, чем разовое смещение весов на основе фундаментальных показателей (corporate tilt). При этом медианные значения коэффициента Шарпа для большинства стратегий остаются отрицательными, что показывает неоднородность окон: средний результат улучшается за счет отдельных более удачных периодов, которые математически перекрывают просадки в остальных периодах




Рисунок 5. Rolling-window 2024–2025: итоговый портфель против риск-ядра и корпоративного tilt

Главный вывод из rolling-window проверки состоит в том, что результаты неоднозначны. Статический test показывает преимущество корпоративно-смещенной стратегии относительно `Equal`, но rolling-window режим сильнее поддерживает `MinVar_LW` и итоговый портфель, основанный на риск-ядре. Поэтому модель полезнее трактовать как аналитическую портфельную систему, чем как доказательство одной универсально лучшей стратегии.

5.7 Ограничения эмпирической части

У полученных результатов есть несколько ограничений. Во-первых, даже дневная история за 2019-2025 гг. остается ограниченной для финансовых рядов: рынок проходит разные режимы, и одна модель может вести себя по-разному в спокойные и стрессовые периоды. Во-вторых, корпоративные признаки публикуются реже, чем цены, поэтому их нужно лагировать; это уменьшает риск заглядывания в будущее, но снижает частоту обновления корпоративного сигнала.

В-третьих, корпоративные признаки могут быть мультиколлинеарны. Капитализация, `free float` и ликвидность связаны между собой; `P/E` и `P/B` также не всегда независимы. Поэтому коэффициенты корпоративных регрессий нельзя читать как причинные эффекты. В-четвертых, портфельная оптимизация чувствительна к ограничениям по весам, периоду оценки и выбранной метрике риска. Даже `Ledoit-Wolf` и `CVaR` не устраняют эту чувствительность полностью.

Поэтому объединение `PCA`, устойчивой ковариационной оценки, корпоративных признаков и хвостовых метрик дает содержательную и воспроизводимую систему анализа риска. Но на имеющихся данных нельзя утверждать, что найден один универсально лучший портфель для всех рыночных условий.

5.8 Итог по эмпирической части

Эмпирическая часть показала, что выбранная схема может быть реализована на фактических данных Московской биржи. PCA выделяет сильный общий фактор: первая компонента объясняет 53.17% дисперсии, а первые шесть компонент - 71.29%. Ledoit-Wolf оценка дает умеренное сжатие ковариационной матрицы со shrinkage 0.100. Корпоративный блок позволяет построить интерпретируемый сигнал, где наибольшие веса получили P/B, дивидендная доходность и NetDebt/EBITDA.

В статическом out-of-sample периоде 2024–2025 гг. лучшую Sharpe-метрику среди стратегий показал `CorpTilt_MV`, а итоговый портфель `Final_Recommended_Portfolio` снизил потери относительно равновзвешенного портфеля, но не стал лучшей стратегией по всем метрикам. В rolling-window режиме наиболее устойчивым оказалось риск-ядро `MinVar_LW`, а итоговый портфель был близок к нему. Это подтверждает основную идею работы: многомерная модель полезна как инструмент анализа структуры риска и построения проверяемых портфельных решений, но ее инвестиционные результаты говорят о том, что проект требует довольно обширной доработки.

5.9 Распределение обязанностей:

Юсуфова Полина - Обзор литературы, основная часть теории (1, 2.1-2.6), Эмпирическая проверка (3), Расчетная спецификация модели (4), Эмпирическая часть (5.1-5.3), Код - начало (выгрузка данных MOEX ISS, описательная статистика, очистка данных, МГК для лог-доходностей).

Моисеев Егор - заключительная часть теории (разделы 2.7–2.8), эмпирическая часть 5.4–5.8. В коде выполнена основная расчетная часть: подготовка и использование корпоративных характеристик, построение корпоративного сигнала, создание портфелей, расчет портфельных метрик, сравнение стратегий на test-периоде и в rolling-window проверке, выбор итогового портфеля и интерпретация полученных результатов.

5.10 Использование ИИ:

При написании КР мы использовали ИИ в технических целях при оформлении текста и программного кода. Использование ИИ было направлено на оптимизацию рутинных процессов, а именно: Оформление: ИИ применялись для подготовки и отладки исходного кода в Overleaf (LaTeX), что позволило структурировать математические формулы Программная реализация: ИИ использовался для написания и оптимизации рутинных фрагментов кода на языке Python (включая предобработку данных и реализацию вспомогательных статистических функций, а также написание структурно объемных функций), что позволило сократить время на написание технически стандартных блоков алгоритма.

ЗАКЛЮЧЕНИЕ

В работе была построена и проверена портфельная схема, объединяющая несколько блоков: ковариационный анализ доходностей, PCA/МГК, устойчивое оценивание ковариационной матрицы, корпоративные характеристики компаний и хвостовые меры риска. В отличие от предварительной версии, где эмпирическая часть была сформулирована как план, в итоговой версии расчеты доведены до проверки на расширенной выборке из 25 акций Московской биржи.

Цель работы можно считать достигнутой в том смысле, что портфельный подход был реализован на конкретных данных за 2019–2025 гг. и оценен по заранее заданным метрикам: годовой доходности, волатильности, Sharpe, VaR 95%, ES 95%, максимальной просадке и концентрации весов. В расчетах отдельно выделены обучающий период 2019–2023 гг., статический out-of-sample период 2024–2025 гг. и rolling-window проверка с последовательным обновлением данных.

Полученные результаты показывают, что российская выборка имеет выраженную общую факторную структуру: первая PCA-компонента объясняет 53.17% дисперсии доходностей, а первые шесть компонент – 71.29%. Это подтверждает необходимость многомерного подхода: риски активов нельзя корректно рассматривать как независимые. Ledoit–Wolf shrinkage дал умеренное сжатие ковариационной матрицы, поэтому MinVar_LW был использован как риск-ядро портфельной системы.

Корпоративный блок оказался полезен прежде всего как интерпретационный и ранжирующий инструмент. Наибольшие итоговые веса получили P/B, дивидендная доходность и NetDebt/EBITDA. В статическом test 2024–2025 гг. стратегия CorpTilt_MV показала лучший Sharpe среди рассмотренных стратегий и заметно меньшие потери относительно равновзвешенного портфеля. Однако в rolling-window режиме более устойчиво выглядели MinVar_LW и близкий к нему Final_Recommended_Portfolio. Поэтому результаты нельзя свести к утверждению, что корпоративный tilt всегда лучше риск-ядра.

Главный вывод работы состоит в том, что объединение статистических факторов, устойчивой матрицы риска, корпоративных признаков и хвостовых метрик позволяет получить более содержательную систему анализа портфеля, чем использование каждого элемента отдельно. При этом модель не дает гарантии универсального превосходства над простым benchmark. Равновзвешенный портфель остается важной базовой стратегией, а преимущество сложной модели должно проверяться на будущих данных и в разных рыночных режимах.

К ограничениям работы относятся длина доступного периода, неоднородность российского рынка, редкая публикация корпоративных данных, мультиколлинеарность признаков и чувствительность оптимизации к ограничениям по весам. Дальнейшее развитие исследования может быть связано с более строгой проверкой транзакционных издержек, альтернативными правилами turnover-контроля, учетом отраслевых ограничений и расширением корпоративной базы. Однако уже в текущей версии расчеты показывают, что выбранная методология подходит для анализа взаимосвязи

между рыночной структурой, корпоративными характеристиками и портфельным риском.

СПИСОК ЛИТЕРАТУРЫ

- [1] Markowitz, H. Portfolio Selection. *The Journal of Finance*, 1952.
- [2] Fama, E. F., French, K. R. The Cross-Section of Expected Stock Returns. *The Journal of Finance*, 1992.
- [3] Fama, E. F., French, K. R. Common Risk Factors in the Returns on Stocks and Bonds. *Journal of Financial Economics*, 1993, 33, 3–56.
- [4] Connor, G., Korajczyk, R. A. Risk and Return in an Equilibrium APT: Application of a New Test Methodology. *Journal of Financial Economics*, 1988, 21(2), 255–289.
- [5] Ledoit, O., Wolf, M. Improved Estimation of the Covariance Matrix of Stock Returns with an Application to Portfolio Selection. *Journal of Empirical Finance*, 2003, 10(5), 603–621.
- [6] Acerbi, C., Tasche, D. Expected Shortfall: A Natural Coherent Alternative to Value at Risk. *Economic Notes*, 2002, 31(2), 379–388.
- [7] Rockafellar, R. T., Uryasev, S. Optimization of Conditional Value-at-Risk. *Journal of Risk*, 2000, 2(3), 21–41.
- [8] Chen, B., Huang, S.-F., Pan, G. High Dimensional Mean–Variance Optimization through Factor Analysis. *Journal of Multivariate Analysis*, 2015, 133, 140–159.
- [9] Lyle, M. R., Yohn, T. L. Fundamental Analysis and Mean-Variance Optimal Portfolios. *The Accounting Review*, 2021, 96(6), 303–327.
- [10] Галустян, М. Ж. Использование метода главных компонент при отборе факторов для прогнозирования фондового рынка России. *Известия Тульского государственного университета. Экономические и юридические науки*, 2016, № 2-1, с. 176–183.
- [11] Крицкий, О. Л., Ульянова, М. К. Определение многомерного финансового риска портфеля акций. *Прикладная эконометрика*, 2007, № 4(8), с. 3–17.
- [12] Кретинин, И. А. Применение моделей авторегрессионной условной гетероскедастичности в задаче моделирования условных ковариаций доходностей финансовых активов. *Финансы и кредит*, 2010, № 24(408), с. 73–77.
- [13] Едророва, В. Н., Россохин, В. В. Анализ корреляционных рисков российского фондового рынка и их влияния на характеристики инвестиционного портфеля. *Экономический анализ: теория и практика*, 2014, № 17(368), с. 30–36.

- [14] Кудрявцев, А. А. Модель выбора инвестиционного портфеля на основе квантильных мер риска. *Вестник СПбГУ. Серия «Экономика»*, 2008, Вып. 4, с. 95–102.